

الكلية متعددة التخصصات - ورازات
+٠٢٤٧٠١+ +٠٨+٤٣١٤+ - ٧٠٠٣٠٣٠+
FACULTÉ POLYDISCIPLINAIRE DE OUARZAZATE



MATHÉMATIQUE APPLIQUER POUR LA SCIENCE DES DONNÉES
(MASD)

Rapport de Mémoire de Fin d'Etudes :

Détection et classification automatisées des tumeurs cérébrales à partir d'images par résonance magnétique (IRM)

Réalisé par :

Fatima-zohra JELLALI

Encadré par :

Prof. Khalid AKHLIL

Soutenu le 26 Juin 2024 devant le jury :

| | | |
|---------------------------|---|--------------|
| Prof.AKHLIL khalid | Faculté Polydisciplinaire de Ouarzazate | Encadrant |
| Prof.GAOU Salma | Faculté Polydisciplinaire de Ouarzazate | Examinatrice |
| Prof.TRIBAK Hicham | Faculté Polydisciplinaire de Ouarzazate | Examineur |

Année Universitaire : 2023-2024

DEDICACES

Je dédie humblement ce travail et exprime ma profonde gratitude :

À mes chers parents

Vous êtes mes héros. Votre dévouement, vos sacrifices et votre persévérance ont été les moteurs qui m'ont poussé à aller de l'avant. Votre confiance en moi m'a donné la force de surmonter les obstacles et d'atteindre mes objectifs. Votre amour incommensurable a illuminé chaque pas de ma vie.

À mes chers frère et ma chère sœur

Vous êtes mes compagnons de vie et mes meilleurs amis. Votre présence joyeuse, votre encouragement constant et votre soutien inconditionnel m'ont donné la force de me dépasser. Nos liens indéfectibles sont une source infinie de bonheur et de réconfort.

À tous mes amis

Pour leur support moral et leur encouragement tout au long de mes études, bonne continuation et bon courage pour la suite.

À toute ma famille

Pour leur soutien tout au long de mon parcours universitaire.

Que ce travail soit l'accomplissement de vos vœux tant allégués, et le fruit de votre soutien infailible.

Merci d'être toujours là pour moi

Remerciements

Avant d'entamer ce rapport, je tiens tout d'abord à exprimer ma profonde gratitude envers Allah, le Tout-Puissant et Miséricordieux, pour m'avoir accordé la force, le courage et la patience nécessaires à la réalisation de ce modeste travail.

Je souhaite également exprimer ma sincère reconnaissance envers mon encadrant, M.AKHLIL Khalid, pour ses précieux conseils, son assistance inestimable tout au long de cette période de travail, ainsi que pour son soutien constant et ses orientations.

Mes remerciements vont également à l'ensemble des membres honorables du jury, Mme.GAOU Salma, M.TRIBAK Hicham qui ont accepté d'évaluer ce travail avec bienveillance.

Je tiens à exprimer ma profonde gratitude à toute l'équipe pédagogique de la Faculté Polydisciplinaire de Ouarzazate (FPO). Votre engagement envers notre formation, votre dévouement sans faille, et votre capacité à nous inspirer tout au long de ce parcours académique ont été inestimables. Vous avez su créer un environnement d'apprentissage enrichissant et stimulant, et votre soutien constant a été essentiel à notre réussite. Merci pour votre temps, votre patience, et vos précieux enseignements.

Je tiens à remercier chaleureusement mes parents, mes frères et mes proches pour leur amour, leur soutien constant et leur encouragement indéfectible tout au long de mon parcours académique.

Enfin, je souhaite exprimer ma gratitude à mes amis pour leur présence et leur soutien précieux.

Résumé :

La détection précoce des tumeurs cérébrales est un enjeu critique pour optimiser la prise en charge médicale. Cette étude propose une solution innovante basée sur l'apprentissage automatique et profond pour automatiser la classification des IRM cérébrales, en combinant méthodes classiques (SVM, Random Forest, XGBoost) et architectures avancées (CNN, ResNet50, VGG16, EfficientNetB0).

Les données ont été rigoureusement prétraitées (recadrage, normalisation, augmentation) et évaluées via des métriques robustes (précision, rappel, F1-score). Les résultats démontrent :

Classification binaire : Le CNN personnalisé atteint une précision de 96%, surpassant les modèles classiques (SVM : 94%, XGBoost : 94%).

Classification multi-classe : EfficientNetB0 obtient une performance exceptionnelle (99.31% de précision), avec des scores $F1 > 0.98$ pour toutes les classes (gliome, méningiome, tumeur hypophysaire, sain).

Ces travaux valident l'efficacité des modèles pré-entraînés et du transfert learning pour un diagnostic assisté par ordinateur, offrant une alternative fiable aux méthodes traditionnelles.

Les mots clés : Détection précoce, Tumeurs cérébrales, IRM, Apprentissage profond, EfficientNetB0, CNN, Classification binaire/multi-classe, SVM, XGBoost, Diagnostic automatisé, Random Forest.

Abstract :

Early detection of brain tumors is crucial to improve patient outcomes. This study leverages machine and deep learning to automate MRI brain image classification, comparing traditional methods (SVM, Random Forest, XGBoost) with state-of-the-art architectures (CNN, ResNet50, VGG16, EfficientNetB0).

Data was preprocessed (cropping, normalization, augmentation) and evaluated using robust metrics (accuracy, precision, F1-score). Key findings include :

Binary classification : The custom CNN model achieved 96% accuracy, outperforming classical approaches (SVM : 94%, XGBoost : 94%).

Multi-class classification : EfficientNetB0 delivered exceptional performance (99.31% accuracy), with F1-scores > 0.98 across all tumor types (glioma, meningioma, pituitary) and healthy cases.

This research highlights the potential of transfer learning and pre-trained models to support accurate, automated diagnosis, reducing reliance on time-consuming manual analysis.

Keywords : Early detection, Brain tumors, MRI, Deep learning, EfficientNetB0,

CNN, Binary/multi-class classification, SVM, XGBoost, Computer-aided diagnosis, Random Forest.

Table des matières

| | |
|--|----------|
| Table des matières | 5 |
| Table des figures | 8 |
| Introduction générale | 10 |
| Chapitre 1 : Généralités sur la classification des tumeurs cérébrales : contexte clinique et état de l'art | 12 |
| 1. Introduction : | 12 |
| 2. Tumeur cérébrale : | 12 |
| 2.1 Définition : | 12 |
| 2.2 Tumeur cérébrale primaire et tumeur cérébrale métastatique ou secondaire : | 13 |
| 2.3 Tumeurs cérébrales bénignes et tumeurs cérébrales malignes : | 13 |
| 2.3.1 Tumeurs cérébrales bénignes : | 13 |
| 2.3.2 Tumeurs cérébrales malignes : | 13 |
| 3. Types des tumeurs du cerveau | 14 |
| 3.1 Symptômes de la Tumeur Cérébrale | 14 |
| 3.2 Classification des Tumeurs Cérébrales | 14 |
| 3.2.1 Les Gliome : | 15 |
| 3.2.2 Glioblastome : | 15 |
| 3.2.3 Méningiome : | 15 |
| 3.2.4 Médulloblastome : | 15 |
| 3.2.5 Adénomes Hypophysaires : | 16 |
| 3.2.6 Lymphome cérébral : | 16 |
| 4. Diagnostic d'une tumeur du cerveau | 16 |
| 5. Imagerie par résonnance magnétique (IRM) : | 17 |
| 5.1 Définition des IRM : | 17 |
| 5.2 Principales composantes d'IRM : | 17 |
| 5.3 Acquisition des images IRM | 18 |
| 5.4 Principe de Fonctionnement d'IRM | 19 |
| 5.5 Les avantages de l'IRM : | 19 |
| 5.6 Les inconvénients de l'IRM : | 20 |
| 6. Travaux antérieurs : | 20 |

| | | |
|---|--|----|
| 7. | Conclusion | 24 |
| Chapitre 2 : Les atouts de l'intelligence artificielle : l'apprentissage automatique, l'apprentissage profond | | |
| 1. | Introduction | 25 |
| 2. | Définition de la vision par ordinateur | 25 |
| 3. | Définition de l'analyse d'image et ses divers niveaux | 26 |
| 4. | Les paradigmes de l'apprentissage automatique et l'apprentissage profond | 26 |
| 4.1 | L'apprentissage automatique | 26 |
| 4.1.1 | Machines à Vecteurs de Support | 27 |
| 4.1.2 | Forêts aléatoires (Random Forest) | 28 |
| 4.1.3 | XGBoostClassifier(XGBClassifier) | 29 |
| 4.2 | L'apprentissage profond | 30 |
| 4.2.1 | Les réseaux de neurones convolutifs (CNN) | 30 |
| 4.3 | Description de quelques modèles des réseaux de neurone convolutifs | 33 |
| 4.3.1 | EfficientNet50 : | 33 |
| 4.3.2 | ResNet50 | 34 |
| 4.3.3 | Modèle VGG16 | 35 |
| 5. | Conclusion | 36 |
| Chapitre 3 : Méthodologie,implémentation et résultats | | |
| 1. | Introduction | 37 |
| 2. | Environnement de travail : | 38 |
| 2.1 | Ressource matériel : | 38 |
| 2.2 | Outils de programmation : | 38 |
| 2.3 | Bibliothèques utilisées : | 40 |
| 3. | Les techniques de préparation des données : | 40 |
| 3.1 | Recadrage des images | 40 |
| 3.2 | Redimensionnement | 41 |
| 3.3 | Normalisation | 41 |
| 3.4 | Mélanger les données | 42 |
| 3.5 | Division des données | 42 |
| 3.6 | Encodage One-Hot | 43 |
| 3.7 | Augmentation des données | 43 |
| 4. | Mesures de performance utilisées : | 44 |
| 4.1 | Matrice de Confusion : | 44 |
| 4.2 | Précision de la classification (Accuracy) : | 45 |
| 4.3 | Précision (Precision) : | 45 |
| 4.4 | Rappel (Recall) : | 45 |
| 4.5 | F-mesure (F1-score) : | 45 |
| 5. | Application1 : Classification Binaire | 46 |

| | | |
|-------|--|----|
| 5.1 | Acquisition de la base de données | 46 |
| 5.2 | Modèles proposes | 46 |
| 5.2.1 | Random Forest | 46 |
| 5.2.2 | Support Vector Machine (SVM) | 47 |
| 5.2.3 | XGBoost (Extreme Gradient Boosting) | 48 |
| 5.2.4 | Réseau neuronal convolutionnel (CNN) | 48 |
| 5.2.5 | ResNet101 | 50 |
| 5.2.6 | EfficientNetB0 | 52 |
| 5.2.7 | Résumé des résultats de classification binaire | 54 |
| 6. | Application2 : Classification Multi-classe | 54 |
| 6.1 | Acquisition de la base de données | 55 |
| 6.2 | Modèles proposes | 56 |
| 6.2.1 | EfficientNetB0 | 56 |
| 6.2.2 | VGG16 | 59 |
| 6.2.3 | ResNet50 | 62 |
| 6.2.4 | Résumé des résultats de classification multi-classes | 64 |
| 7. | Présentation du système : | 65 |
| 8. | Les résultats du système : | 66 |
| 9. | Conclusion : | 66 |

| | |
|----------------------|-----------|
| Bibliographie | 69 |
|----------------------|-----------|

Table des figures

| | | |
|----|---|----|
| 1 | caractéristiques des tumeurs malignes et bénignes | 14 |
| 2 | tumeurs cérébrales les plus courants. | 15 |
| 3 | Local informatique | 17 |
| 4 | Appareille IRM GE | 17 |
| 5 | Principe général d'un système informatisé d'imagerie. | 19 |
| 6 | Problème de classification à deux classes en haut avec une séparation linéaire et en bas avec une séparatrice non linéaire. | 28 |
| 7 | Exemple de la structure d'un arbre de décision. | 29 |
| 8 | Exemple de XGBoostClassifier. | 30 |
| 9 | Architecture d'un réseaux de neurones convolutifs | 31 |
| 10 | Couches convolutives. | 32 |
| 11 | Couches de pooling. | 32 |
| 12 | Couches Entièrement Connectées. | 33 |
| 13 | Architecture générale d'EfficientNet. | 34 |
| 14 | Architecture générale de ResNet50 | 35 |
| 15 | L'architecture du modèle VGG16. | 36 |
| 16 | le schéma fonctionnel de la méthode proposée. | 37 |
| 17 | Logo python | 38 |
| 18 | Logo Colab | 39 |
| 19 | Logo Streamlit | 39 |
| 20 | Logo Visual Studio Code | 39 |
| 21 | Illustration d'une image recadrée | 41 |
| 22 | les Tailles d'images les plus fréquentes | 41 |
| 23 | Division des données | 43 |
| 24 | Encodage One-Hot | 43 |
| 25 | Augmentation des données | 44 |
| 26 | La matrice de confusion. | 44 |
| 27 | Matrice de confusion et rapport de classification du Random Forest. | 47 |
| 28 | Support Vector Machine (SVM). | 47 |
| 29 | XGBoost (Extreme Gradient Boosting). | 48 |
| 30 | Réseau neuronal convolutionnel (CNN). | 49 |
| 31 | Learning Curve (CNN) | 49 |

| | | |
|----|--|----|
| 32 | ResNet101. | 51 |
| 33 | Learning Curve ResNet101 | 51 |
| 34 | EfficientNetB0. | 53 |
| 35 | Learning Curve EfficientNetB0 | 53 |
| 36 | Architecture globale du Modèle propose. | 55 |
| 37 | EfficientNetB0(classification multi-classes). | 57 |
| 38 | Learning Curve EfficientNetB0(classification multi-classes) | 58 |
| 39 | Resultat du EfficientNetB0. | 59 |
| 40 | VGG16(classification multi-classes). | 60 |
| 41 | Learning Curve VGG16(classification multi-classes) | 61 |
| 42 | Resultat du VGG16. | 62 |
| 43 | ResNet50(classification multi-classes). | 63 |
| 44 | Learning Curve ResNet50(classification multi-classes) | 63 |
| 45 | Resultat du ResNet. | 64 |
| 46 | Interface principale de système. | 65 |
| 47 | Détection et classification en temps réel des Tumeurs Cérébrale. | 66 |
| 48 | Détection et classification en temps réel des Tumeurs Cérébrale. | 66 |

Introduction Générale

À l'ère de la révolution numérique et de l'intelligence artificielle, le domaine médical fait face à des défis majeurs dans le diagnostic précoce et la classification précise des tumeurs cérébrales. Ces pathologies, bien que relativement rares, comptent parmi les plus agressives et les plus complexes à traiter en raison de leur localisation et de leur hétérogénéité. La nécessité d'améliorer l'efficacité du diagnostic, de réduire les délais d'interprétation et de garantir une précision inégalée dans l'analyse des images IRM a conduit à l'adoption croissante de technologies avancées telles que la vision par ordinateur et l'apprentissage profond. Ces outils émergent comme des solutions clés, capables de transformer les processus traditionnels d'examen médical.

Pour les professionnels de santé, l'exactitude du diagnostic des tumeurs cérébrales est cruciale, non seulement pour la survie des patients mais aussi pour optimiser les plans de traitement. Des évaluations automatisées et précises peuvent réduire considérablement le temps nécessaire à l'analyse des images, tout en minimisant les risques d'erreurs humaines et en améliorant la reproductibilité des résultats. Cela permet notamment d'éviter des traitements inappropriés et des interventions chirurgicales inutiles.

Ce projet vise à exploiter les technologies de pointe de l'intelligence artificielle pour automatiser la détection et la classification des tumeurs cérébrales à partir d'images IRM. En utilisant des techniques avancées d'apprentissage automatique et profond, le système développé pourra identifier de manière fiable et rapide les différentes catégories de tumeurs (gliomes, méningiomes, tumeurs hypophysaires) ainsi que les tissus sains. Cette initiative promet d'améliorer significativement la rapidité et l'objectivité des diagnostics, tout en réduisant la charge de travail des radiologues.

Notre ambition est de révolutionner le processus de diagnostic des tumeurs cérébrales en exploitant la puissance de l'intelligence artificielle. En rendant les analyses plus rapides et plus précises, nous contribuons à améliorer la prise en charge des patients et à optimiser l'utilisation des ressources médicales. Avec des techniques avancées comme les réseaux de neurones convolutifs (CNN) et le transfert learning, nous visons une automatisation intelligente de l'analyse des IRM, ce qui accélère les diagnostics, réduit les erreurs d'interprétation et améliore la documentation des cas, renforçant ainsi la qualité des soins.

Ce mémoire se positionne à la pointe de l'innovation dans le diagnostic médical assisté par ordinateur. En utilisant des algorithmes d'apprentissage profond de dernière génération comme EfficientNetB0 et ResNet50, nous proposons des solutions capables de détecter et classer avec une grande précision les tumeurs cérébrales, redéfinissant ainsi

les standards dans le domaine de l'imagerie médicale et améliorant l'efficacité des diagnostics pour les hôpitaux et les centres de radiologie..

Dans le cadre de ce projet, ce m'emoire se structure en plusieurs chapitres.

Chapitre 1 : Généralités sur la classification des tumeurs cérébrales - Ce chapitre présente le contexte clinique des tumeurs cérébrales, leurs différents types et les méthodes de diagnostic actuelles, avec un focus particulier sur l'imagerie par résonance magnétique (IRM).

Chapitre 2 : Les atouts de l'intelligence artificielle - Ce chapitre expose les fondements théoriques de l'apprentissage automatique et profond, en mettant l'accent sur les architectures de réseaux de neurones utilisées dans le projet (CNN, VGG16, ResNet, EfficientNet).

Chapitre 3 : Méthodologie, implémentation et résultats - Ce chapitre détaille l'approche technique adoptée, depuis le prétraitement des images jusqu'à l'évaluation des modèles, en présentant les résultats obtenus pour la classification binaire et multi-classe

Chapitre 4 : Conclusion et perspectives - Ce dernier chapitre synthétise les contributions majeures du travail, discute des applications potentielles dans le milieu médical et propose des pistes d'amélioration pour des recherches futures.

À travers cette étude, nous démontrons comment l'intelligence artificielle peut devenir un allié précieux pour les professionnels de santé, en offrant des outils d'aide au diagnostic à la fois performants et accessibles. Les résultats obtenus ouvrent la voie à une nouvelle ère dans le diagnostic des tumeurs cérébrales, où la technologie vient renforcer l'expertise médicale pour le bénéfice des patients.

Chapitre 1 : Généralités sur la classification des tumeurs cérébrales : contexte clinique et état de l'art

1 Introduction :

Les tumeurs cérébrales sont un problème de santé important pour tous les groupes d'âge, et les données suggèrent que leur incidence est en augmentation. Chez les nourrissons et les jeunes enfants, les tumeurs du cerveau sont la deuxième forme de cancer la plus courante. Chez les adolescents et les jeunes adultes, les tumeurs cérébrales vont du cinquième au huitième cancer le plus fréquent. Dans la population âgée, l'incidence des tumeurs cérébrales, primitives et métastatiques, est en augmentation. Les tumeurs cérébrales primaires ont une prévalence de 14,7 pour 100 000 aux États-Unis, et il y a environ 80 000 à 100 000 nouvelles tumeurs cérébrales Métastatiques chaque année. Ainsi, pratiquement tous les médecins, quelle que soit leur spécialité, rencontreront des patients atteints de tumeurs cérébrales et la plupart des familles auront un parent ou un ami atteint d'une tumeur cérébrale.

Dans ce chapitre, nous allons définir les notions de base sur les tumeurs, par la suite, nous allons présenter en détaille la tumeur cérébrale, ses types et l'imagerie par résonnance magnétique qui est utilisée pour la diagnostiquer..À la fin, le chapitre présente un résumé de l'état de l'art de la classification automatique des tumeurs cérébrales.

2 Tumeur cérébrale :

2.1 Définition :

Le cerveau peut être le siège de près d'une dizaine de types de tumeurs qui sont classées selon les cellules qui les composent. Une tumeur est toute masse qui résulte d'une multiplication (division) accumulée de cellules anormales. Elle peut également être appelée un néoplasme ou une excroissance (masse).

Tous ces phénomènes sont aussi mis en jeu lors du renouvellement des cellules dont la durée de vie est limitée. Au sein d'un tissu, l'équilibre entre ces processus est à l'origine de l'homéostasie tissulaire. Les anomalies de cette homéostasie, par augmentation de la prolifération et/ou diminution de la mort cellulaire, sont à l'origine de l'accumulation des cellules aboutissant à la formation d'une tumeur macroscopiquement visible

2.2 Tumeur cérébrale primaire et tumeur cérébrale métastatique ou secondaire :

- **Les tumeurs cérébrales dites « primaires »** : sont les cellules qui se développent directement dans une partie des cellules cérébrales et leur enveloppe. Elles peuvent être bénignes ou malignes.
- **Les tumeurs cérébrales secondaires (ou métastatiques)** : sont constituées de cellules provenant d'un autre organe, plus souvent des poumons, des seins, des reins ou de la peau (mélanome). Les tumeurs moins cellulaires de ces organes peuvent migrer vers le cerveau en empruntant le plus souvent la voie sanguine.

2.3 Tumeurs cérébrales bénignes et tumeurs cérébrales malignes :

Les tumeurs ne sont pas nécessairement des tumeurs cancéreuses, elles peuvent être existes en trois catégories : On constate que les tumeurs non-cancéreuses sont appelées tumeurs bénignes, et des tumeurs cancéreuses sont appelées tumeurs malignes. Et enfin, les tumeurs intermédiaires sont dites **atypiques** ou **évolutives**, ces tumeurs sont initialement bénignes et peuvent se développer en cancer dans un laps de temps variable

2.3.1 Tumeurs cérébrales bénignes :

Les tumeurs cérébrales bénignes sont constituées de cellules qui croissent lentement. Bien qu'elles n'envahissent pas les tissus avoisinants, elles peuvent être à l'origine des symptômes importants si elles exercent une pression sur des zones sensibles du cerveau. Si une tumeur bénigne interfère avec des fonctions vitales (parole, mobilité, etc.), ses effets peuvent être aussi dangereux que ceux d'une tumeur maligne.

2.3.2 Tumeurs cérébrales malignes :

Les tumeurs cérébrales malignes contiennent des cellules qui se multiplient rapidement, leurs contours ne sont pas bien définis, elles croissent rapidement et peuvent envahir et endommager des structures cérébrales importantes. Toutes les lésions cérébrales métastatiques sont considérées comme malignes.

LA Figure 1 compare les caractéristiques des tumeurs malignes et bénignes

| Tumeur bénigne | Tumeur maligne |
|---|------------------------------------|
| Bien limitée | Mal limitée |
| Encapsulée, exérèse simple | Non encapsulée |
| Bien différenciée | Différenciation variable |
| Cellules régulières | Cellules irrégulières |
| Croissance lente | Croissance rapide |
| Refole sans destruction le tissu normal | Envahit et détruit le tissu normal |
| Pas de récurrence locale | Récurrence possible |
| Pas de métastase | Métastase |

FIGURE 1 – caractéristiques des tumeurs malignes et bénignes

3 Types des tumeurs du cerveau

La tumeur cérébrale désigne toutes les tumeurs qui se situent à l'intérieur du crâne et qui peuvent se développer dans n'importe quelle zone du cerveau. Autrement dit, elles sont des tumeurs qui naissent à l'intérieur du cerveau. Cependant cette tumeur demeure la plus mortelle à cause de sa nature agressive et ses caractéristiques hétérogènes.

Il existe un grand nombre de tumeurs du cerveau différentes. Selon leur localisation, leur taille et la vitesse à laquelle elles se développent, ces tumeurs n'entraînent pas les mêmes symptômes et n'ont pas la même gravité. Les tumeurs du cerveau portent généralement le nom des cellules à partir desquelles elles se développent.

3.1 Symptômes de la Tumeur Cérébrale

Les Symptômes d'une Tumeur Cérébrale se diffèrent selon le volume, la vitesse de propagation et la localisation de tumeur. Les symptômes les plus fréquents sont :

- **Des maux de tête :** qui sont liés à une augmentation de la pression à l'intérieur du crâne.
- **Des troubles fonctionnels :** qui sont directement liés à la localisation de la tumeur et aux fonctions gérées dans cette zone du cerveau.
- **Des crises d'épilepsie**

3.2 Classification des Tumeurs Cérébrales

La classification officielle des tumeurs cérébrales, proposée par l'organisation mondiale de la santé (OMS), s'effectue selon des critères d'origine cellulaire et leur degré de malignité.

Qu'elle soit la tumeur primitive, secondaire, bénigne ou maligne, il existe des dizaines de TC différentes, par ailleurs les médecins classent la tumeur en fonction de trois facteurs :

- Sa localisation dans le cerveau.
- Son degré d'agressivité.
- Son type.

Parmi les TC primitives les plus fréquents on trouve :




FIGURE 2 – tumeurs cérébrales les plus courants.

3.2.1 Les Gliome :

Ces sont les cancers les plus connus, appelés comme ainsi parce que la cellule endommagée est la cellule gliale qui se trouve autour des neurones. La classification prend en compte le degré d'agressivité. Il y a plusieurs types, de I à IV, le premier étant le moins agressif

3.2.2 Glioblastome :

Il s'agit du grade IV des gliomes, il est le plus agressif et le plus répandu. Les traitements connus aujourd'hui ne permettent pas de guérir cette maladie. Il n'a que des moyens par chimiothérapie et radiothérapie de rallonger l'espérance de vie à un an, un an et demi.

3.2.3 Méningiome :

Le méningiome affecte les cellules des méninges et peut être localisé autour du cerveau et de la moelle épinière. La forme la plus courante de méningiome est bénigne, et son pronostic favorable

3.2.4 Médulloblastome :

C'est une lésion maligne au niveau de la moelle épinière et du cervelet. Cette lésion tumorale apparaît principalement chez les enfants et les adolescents. Cela provoque comme

symptôme des troubles de la marche, de l'équilibre, une hypertension intracrânienne. Il y a des traitements spécifiques et la possibilité de guérir selon le stade d'intervention

3.2.5 Adénomes Hypophysaires :

C'est une tumeur le plus souvent bénigne qui se développe dans la glande de l'hypophyse. Cette glande, située derrière le chiasma optique, dans la fosse hypophysaire de l'os sphénoïde, contient des cellules qui produisent des hormones réglant l'activité de plusieurs organes. Un adénome hypophysaire peut alors créer des déséquilibres hormonaux. En fonction de l'adénome le traitement sera médical ou chirurgical. Les adénomes hypophysaires sont pour la majeure partie des lésions bénignes. Si elles sont malignes, le pronostic est favorable si elles sont traitées à temps détaille le médecin.

3.2.6 Lymphome cérébral :

Le lymphome cérébral touche en particulier les patients immunodéficients et les personnes âgées de plus de 60 ans. Son traitement n'est pas pratiqué partout, car il nécessite une surveillance étroite, une chimiothérapie lourde. Une partie des patients peuvent avoir une rémission très longue et il y a beaucoup de récives. Les spécialistes étudient des traitements avancés à partir de cellule souches afin d'améliorer le pronostic, qui est pour le moment encore défavorable. La survie est plus importante chez les jeunes.

4 Diagnostic d'une tumeur du cerveau

L'imagerie médicale est une discipline médicale mettant en œuvre les moyens actuels pour observer la structure interne du corps humain, le fonctionnement des organes ainsi que le développement interne des maladies en utilisant des sources de rayonnement. Pour établir le diagnostic de métastases cérébrales, on a recours à des techniques d'imagerie médicale permettant de bien visualiser les structures cérébrales. Dans la grande majorité des cas, on réalise :

- **Une imagerie par résonance magnétique ou l'IRM du cerveau :** c'est l'examen le plus fréquent pour diagnostiquer des métastases cérébrales. Cette technique utilisant des produits de contraste est utile pour rechercher des anomalies, qui sont moins visibles avec d'autres techniques d'imagerie médicale, et de mieux caractériser la tumeur ou les métastases
- **Un scanner du cerveau :** c'est un examen proche de l'IRM qui permet grâce aux rayons X d'obtenir des vues du cerveau en coupe, de délimiter avec précision la localisation, la taille et l'extension ou les contours des métastases ainsi que ses répercussions sur le cerveau.

5 Imagerie par résonance magnétique (IRM) :

De nos jours, l'IRM est devenue un outil majeur de l'imagerie médicale moderne, permettant la réalisation d'études importantes à l'échelle d'une population ou aidant les médecins à établir un diagnostic.

5.1 Définition des IRM :

L'IRM est une méthode non invasive de cartographie de la structure interne et de certains aspects de la fonction du corps, notamment du cerveau. Elle utilise un rayonnement électromagnétique non ionisant et semble ne présenter aucun risque lié à l'exposition. Elle utilise un rayonnement radiofréquence (RF) en présence de champs magnétiques soigneusement contrôlés afin de produire des images de coupe transversale de haute qualité du corps dans n'importe quel plan.

L'image IRM est construite en plaçant le patient à l'intérieur d'un grand aimant, qui induit un champ magnétique externe relativement fort. Cela provoque l'alignement des noyaux de nombreux atomes dans le corps, y compris l'hydrogène, avec le champ magnétique, et après l'application ultérieure du signal RF, l'énergie est libérée du corps, détectée et utilisée pour construire l'image IRM par ordinateur.



FIGURE 3 – Local informatique



FIGURE 4 – Appareille IRM GE

5.2 Principales composantes d'IRM :

Un système IRM est composé de quatre composants principaux : l'aimant principal, les bobines de gradient, les bobines de radiofréquence (RF) et les systèmes informatiques qui contrôlent et interfacent les différents composants.

- **L'aimant principal** est le cœur du système IRM. Produisant le champ magnétique Bo dans lequel le patient est placé. L'unité de mesure de la puissance du champ magnétique de l'IRM est le Tesla. Trois technologies d'aimants existent :

- **Les électro-aimants supraconducteurs** : Un aimant supraconducteur se compose d'une série de bobines enroulées sur une forme cylindrique à l'intérieur d'un bain d'hélium liquide enfermé dans un cryostat. Leur principal inconvénient est le coût du cryogène (hélium liquide).
- **Les aimants permanents** : constitués de matériaux magnétisés de manière permanente, ces aimants n'ont pas besoin d'électricité, ni de cryogène ou de système de refroidissement pour produire un champ magnétique ; leurs principaux inconvénients sont leur poids et leur limite en intensité (0.3T).
- **Les électro-aimants résistifs** : constitués de bobines de fil électrique, ils produisent un champ magnétique lorsque les bobines sont alimentées par un courant électrique, Leurs principaux inconvénients sont leur forte consommation en électricité, leur nécessité de refroidissement et parfois leur poids, surtout lorsqu'un noyau de fer est ajouté pour augmenter le champ magnétique.
- **les bobines de radiofréquence (RF)** : La fonction principale des bobines de gradient, également simplement appelées "gradients", est de permettre le codage spatial du signal RM. Les gradients produisent un champ magnétique supplémentaire qui varie en intensité le long de sa direction et est superposé au champ magnétique principal, permettant ainsi de coder chaque unité de volume élémentaire dans les trois directions de l'espace.
- **les bobines de gradient** : Les bobines radiofréquence sont utilisées pour envoyer des impulsions RF et recevoir le signal renvoyé par le corps du patient, ce qui en fait l'un des déterminants les plus importants du rapport signal sur bruit (SNR) et de l'uniformité du signal.
- **les systèmes informatiques** : Les différents systèmes informatiques intégrés dans un scanner IRM ont plusieurs fonctions. Ils contrôlent les impulsions RF et de gradient, collectent les données et traitent et affichent l'image générée. Ces systèmes travaillent ensemble pour contrôler les RF et les gradients, échantillonner le signal entrant à des intervalles de temps discrets, et produire des images reconnaissables. Un logiciel d'analyse automatisé peut distinguer entre les domaines de fréquence pour traiter les données, et l'analyse peut être effectuée dans le domaine fréquentiel ou temporel. Les données sont ensuite converties en images affichées.

5.3 Acquisition des images IRM

L'IRM permet d'obtenir des images numériques en trois dimensions d'une précision inférieure au millimètre, du cortex, de la substance blanche, du liquide céphalorachidien et des noyaux gris centraux. Deux paramètres réglables cliniquement entrent en jeu lors de l'acquisition : le temps de répétition des séquences d'impulsion (TR), et le temps d'écho (TE). Une acquisition effectuée avec des temps TR et TE courts est dite en T1. Lorsque ces

deux temps sont longs, elle est dite en T2. Enfin lorsque TR est long et TE est court, elle est dite en rho ou densité de proton. Toute l'acquisition peut être caractérisée par rapport à ces trois types particuliers. Ainsi, on parle d'image pondérée en T1 si l'acquisition se rapproche plus de type d'acquisition en T1 que des deux autres types : de façon similaire, on parle d'acquisition pondérée en T2 ou en p. De plus, on peut renforcer le signal de certaines structures sur les séquences pondérées en T1 grâce à l'utilisation d'un agent de contraste tel que le gadolinium.

5.4 Principe de Fonctionnement d'IRM

L'imagerie par résonance magnétique (IRM) utilise un aimant très puissant qui fait « vibrer » les atomes d'hydrogène, éléments qui composent les molécules d'eau de notre corps. Notre organisme est constitué de plus de 65 % d'eau. Au centre de chaque atome d'hydrogène se trouve une particule encore plus petite appelée proton : c'est cette particule qui est à l'origine du phénomène. Une antenne placée autour de la région à examiner va capter les « vibrations » des protons, les protons « vibrent » à des vitesses variables, selon le type de tissu dans lequel ils se trouvent. Cela permet de bien distinguer les différentes structures de l'organisme sur les images obtenues, dont les tumeurs par exemple. L'injection d'un produit de contraste est souvent nécessaire pendant l'examen afin de mieux visualiser la zone à examiner.

Les signaux reçus des millions de protons dans le corps sont réunis pour créer des images en coupes détaillées de l'intérieur du corps. Des images en 2 ou 3 dimensions sont ensuite reconstituées par un ordinateur avant d'être interprétées par un radiologue.

La figure ci-dessous nous montre le processus général d'acquisition d'images.




FIGURE 5 – Principe général d'un système informatisé d'imagerie.

5.5 Les avantages de l'IRM :

- **Pas de radiation ionisante :** Les impulsions RF utilisées en IRM ne causent pas d'ionisation et n'ont aucun effet nocif de la radiation ionisante. Par conséquent,

elles peuvent être utilisées chez les femmes enceintes et les enfants.

- **Non invasif** : L'IRM est non invasive.
- **Résolution de contraste** : C'est l'avantage principal de l'IRM, c'est-à-dire la capacité d'un processus d'imagerie à distinguer les tissus mous adjacents les uns des autres. Il peut manipuler le contraste entre différents tissus en modifiant le motif des impulsions RF.
- **Image multiplanaire** : Avec l'IRM, nous pouvons obtenir des images directes, sagittales, coronales et obliques, ce qui est impossible avec la radiographie et la tomodensitométrie (CT).
- Jusqu'à présent, aucun effet indésirable n'a été constaté

5.6 Les inconvénients de l'IRM :

- **Claustrophobie** : c'est-à-dire une peur morbide des espaces clos, car le patient se trouve à l'intérieur du grand aimant pendant jusqu'à une heure.
- **L'équipement d'IRM est coûteux** : à acheter, à entretenir et à exploiter. Le matériel et les logiciels sont encore en développement.
- **En raison du fort champ magnétique utilisé** : les implants activés électriquement, magnétiquement ou mécaniquement tels que les stimulateurs cardiaques, les défibrillateurs implantables et certaines valves cardiaques artificielles peuvent ne pas pouvoir subir une IRM en toute sécurité.
- L'image par IRM est déformée par le métal, donc l'image est déformée chez les patients avec des clips chirurgicaux ou des stents, par exemple.
- Le patient pourrait développer une réaction allergique au produit de contraste, ou une infection cutanée pourrait se développer au site d'injection.

6 Travaux antérieurs :

De nombreux chercheurs ont discuté des techniques utilisées et appliquées pour la détection et la classification des tumeurs cérébrales. Nous allons dans ce qui suit, passer en revue un certain nombre d'articles.

Vijay Wasule, Poonam Sonar : [33] Dans cet article, un système a été développé pour classifier les images IRM cérébrales en types malins et bénins à l'aide de classificateurs supervisés SVM et KNN. Le système proposé a été appliqué à un ensemble de données cliniques composé de 251 images (85 malignes et 166 bénignes) ainsi qu'à un ensemble de données d'entraînement BRATS 2012 composé de 80 images (50 gliomes de bas grade et 30 gliomes de haut grade). Les résultats obtenus ont montré une précision de 96% et 86% pour le SVM et le KNN respectivement pour la base de données clinique, et de 85% et 72,50% pour le SVM et le KNN respectivement pour la base de données BRATS. Il

a été conclu que le classificateur SVM affiche une précision supérieure à celui du KNN. De plus, il a été observé que l'augmentation du nombre d'images d'entraînement améliore les performances du classificateur SVM. Ces résultats démontrent l'efficacité du système proposé dans la classification automatique des tumeurs cérébrales à partir d'images IRM, ce qui pourrait avoir un impact significatif sur la planification du traitement et les soins aux patients.

Arun Kumar, Alaknanda Ashok, M.A. Ansari : [28] Cet article présente une méthode hybride combinant l'optimisation par essaim de particules (PSO) pour la sélection des caractéristiques et une machine à vecteurs de support (SVM) pour la classification des tumeurs cérébrales. L'objectif est de développer un modèle capable de classer les tumeurs à partir d'images IRM en améliorant la précision et en réduisant le temps de calcul. Les étapes du traitement d'image médicale comprennent le prétraitement de l'image, la segmentation de la région tumorale, l'extraction et la sélection des caractéristiques pertinentes, puis la classification des images. Le modèle hybride PSO-SVM atteint une précision de 95,23%, supérieure à celle du SVM seul (86,82%), avec une spécificité de 94,8% et une sensibilité de 100%. Cette amélioration souligne l'importance de la sélection des caractéristiques pour optimiser les performances des classificateurs d'images.

Dr. Sudipta Roy, Dr. Samarjit Kar, Dr. Debpriyo Roy, et Dr. Nishikanta Bouri : [32] Dans cet article, une nouvelle approche de diagnostic automatisé pour la classification des images IRM cérébrales est présentée. Le processus de classification utilise une combinaison de Transformée en Ondelettes 2D et de la Matrice de Dépendance des Niveaux de Gris Spatiaux (DWT-SGLDM) pour l'extraction des caractéristiques. Pour réduire la taille des caractéristiques, un Algorithme de Recuit Simulé (SA) est appliqué. Une Validation Croisée Stratifiée en K-plis est utilisée pour éviter le surapprentissage. Les paramètres de la machine à vecteurs de support (SVM) sont optimisés à l'aide d'un modèle basé sur l'Algorithme Génétique (GA-SVM). La méthode proposée est évaluée sur un ensemble de données composé de 83 images IRM du cerveau, et elle obtient un taux de classification de 95,65%. Les résultats montrent que cette approche est efficace pour la détection des tumeurs cérébrales, offrant une performance de classification élevée avec une réduction significative du nombre de caractéristiques nécessaires.

Ashfaq Hussain et Ajay Khunteta : [29] Cet article présente une méthodologie pour la segmentation sémantique des tumeurs cérébrales à partir d'images IRM, suivie d'une classification SVM en utilisant les caractéristiques GLCM. L'objectif est de détecter précocement les tumeurs cérébrales pour sauver la vie des patients. Les techniques de segmentation sont utilisées pour détecter et segmenter la région des tumeurs cérébrales à partir des images IRM du cerveau. Les étapes comprennent le filtrage médian pour éliminer le bruit, le stripping du crâne pour isoler la région du cerveau, et la segmentation par watershed pour détecter les régions de tumeur. Les caractéristiques GLCM sont ensuite extraites pour chaque image à l'aide de MATLAB, suivies de la classification SVM.

L'exactitude moyenne obtenue est de 93,05 %, ce qui est supérieur aux modèles conventionnels. Cette approche offre un moyen efficace de détecter les tumeurs cérébrales à partir d'images IRM, ce qui pourrait avoir un impact significatif sur le diagnostic précoce et le traitement des patients.

Marco Alfonse, Abdel-Badeeh M. Salem : [27] Dans cet article, un système de diagnostic automatique des tumeurs cérébrales est présenté, basé sur l'imagerie par résonance magnétique (IRM) et utilisant des techniques telles que la transformation de Fourier rapide (FFT), la segmentation et la machine à vecteurs de support (SVM). Ce système vise à différencier les types de tumeurs cérébrales en tumeurs bénignes ou malignes, en se basant sur des images IRM au format DICOM. L'importance de la détection précoce des tumeurs cérébrales est soulignée, compte tenu de la gravité de cette maladie, et l'efficacité de cette approche est démontrée avec une précision de classification de 98,9%.

Jun Cheng, Wei Huang, Shuangliang Cao, Ru Yang, Wei Yang, Zhaoqiang Yun, Zhijian Wang et Qianjin Feng : [31] Dans cet article, Ces chercheurs ont développé une méthode novatrice pour améliorer la classification des tumeurs cérébrales en utilisant une approche de région augmentée et de partitionnement. Cette méthode consiste à augmenter la région tumorale par dilatation d'image, puis à la diviser en sous-régions pour une analyse plus fine. Trois approches ont été utilisées pour extraire les caractéristiques des images IRM, à savoir l'histogramme d'intensité, la matrice de cooccurrence de niveau de gris (GLCM) et le sac de mots (BoW). Pour la classification, la machine à vecteur de support (SVM) a été employée, démontrant des performances améliorées dans la classification des tumeurs cérébrales, avec des taux de précision atteignant jusqu'à 91,28%. Ces résultats mettent en lumière l'efficacité de l'approche proposée, offrant des perspectives prometteuses pour une classification automatique plus précise des tumeurs cérébrales à partir d'images IRM, ce qui pourrait avoir un impact significatif sur la planification des traitements et les soins aux patients.

M.Z.Zafar , S.M.Adnan , W.Ahmad , J.Ikram , J.Rashid : [30] Dans cet article, une méthode de détection et de classification des tumeurs cérébrales à partir d'images IRM a été mise en place en trois étapes clés. La première étape consiste en un prétraitement où le crâne est éliminé de l'image du cerveau en utilisant le masquage d'image. Ensuite, les caractéristiques sont extraites à l'aide de descripteurs géométriques tels que l'éclipse, la parabole et l'hyperbole. Ces caractéristiques sont ensuite classées à l'aide d'un SVM (Support Vector Machine) pour identifier et classer les tumeurs cérébrales. Cette approche offre une méthode efficace pour la détection automatique des tumeurs cérébrales à partir d'images IRM, avec des résultats prometteurs en termes de précision et d'exactitude dans la classification des tumeurs cérébrales, atteignant une précision de 97.5%.

| Auteurs | Méthodes | Données | Précision |
|--|--|--|------------------------------|
| Vijay Wasule, Poonam Sonar | SVM, KNN | 251 images cliniques, 80 images BRATS 2012 | SVM : 96%, 85% (BRATS) |
| KNN : 86%, 72.5% (BRATS) | | | |
| Arun Kumar, Alaknanda Ashok, M.A. Ansari | PSO-SVM | N/A | PSO- SVM : 95.23% |
| SVM seul : 86.82% | | | |
| Dr. Sudipta Roy et al. | DWT-SGLDM, SA, GA-SVM | 83 images IRM | 95.65% |
| Ashfaq Hussain, Ajay Khunteta | Segmentation sémantique, SVM (GLCM) | N/A | 93.05% |
| Marco Alfonse, Abdel-Badeeh M. Salem | FFT, segmentation, SVM | Images IRM DICOM | 98.9% |
| Jun Cheng et al. | Région augmentée et partitionnement, SVM (histogramme d'intensité, GLCM, BoW) | N/A | 91.28% |
| M.Z. Zafar et al. | Prétraitement (masquage d'image), descripteurs géométriques, SVM | N/A | 97.5% |

TABLE 1 – Résultats de l'état de l'art pour la classification des tumeurs cérébrales.

Discussion :

Les travaux antérieurs examinés présentent une tendance prometteuse dans l'utilisation de l'intelligence artificielle, en particulier l'apprentissage automatique, pour la détection et la classification des tumeurs cérébrales à partir d'images IRM. Ces approches se sont diversifiées, explorant diverses techniques telles que les machines à vecteurs de support (SVM), les réseaux de neurones artificiels, les méthodes d'optimisation par essaim de particules (PSO), et les transformées en ondelettes. Une constatation commune est la performance élevée de ces méthodes, atteignant régulièrement des taux de précision supérieurs à 90%. L'optimisation des algorithmes et la sélection des caractéristiques ont également été explorées avec succès pour améliorer la précision des modèles. En outre, ces recherches ont ouvert la voie à des applications pratiques, notamment des systèmes de diagnostic automatique pour la planification du traitement et les soins aux patients. Cependant, il est crucial de continuer à valider ces méthodes dans des contextes cliniques pour assurer leur fiabilité et leur utilité réelle dans le diagnostic précoce et la prise en charge des tumeurs cérébrales.

7 Conclusion

Ce chapitre a permis d'établir les bases théoriques essentielles sur les tumeurs cérébrales, leur classification et les méthodes de diagnostic par IRM. Nous avons mis en évidence la complexité de ces pathologies et l'importance cruciale d'un diagnostic précoce et précis.

L'analyse de l'état de l'art a révélé le potentiel des approches d'intelligence artificielle, en particulier l'apprentissage profond, pour automatiser et améliorer la classification des tumeurs. Les performances prometteuses des différents modèles étudiés confirment la pertinence de cette orientation technologique dans le domaine médical.

Ces éléments théoriques constituent le socle nécessaire pour aborder dans les chapitres suivants nos contributions méthodologiques et expérimentales dans ce domaine.

Chapitre 2 :Les atouts de l'intelligence artificielle : l'apprentissage automatique, l'apprentissage profond

1 Introduction

Depuis plus d'une décennie, l'intelligence artificielle (IA) a vécu une accélération dans son développement ainsi que son adoption, spécialement pour résoudre les problèmes dans le domaine de diagnostic des images cérébrales (IRM) vu leur faible contraste, frontières floues entre les divers tissus ou bien entre les tissus et les lésions. En effet, ces lacunes ne se différencient pas à l'œil nu où l'intelligence artificielle a pu en extraire des caractéristiques discriminantes pour l'amélioration du diagnostic. Nous évoquons au long de ce chapitre, les paradigmes de l'intelligence artificielle proposés pour l'analyse d'images, l'extraction de descripteurs discriminants en vue de la classification du gliome, désignant le type le plus répandu de tumeur cérébrale primaire maligne avec une incidence et un taux de mortalité élevé.

2 Définition de la vision par ordinateur

La vision par ordinateur est un domaine appartenant à l'intelligence artificielle et qui vise l'analyse et l'interprétation d'images numériques. L'ultime objectif de la vision par ordinateur est de doter la machine avec la capacité de voir et d'interpréter le monde identiquement à un être humain. En effet, à la fin la machine pourra prendre des décisions et effectuer des tâches en se basant sur les informations visuelles qu'elle a reçu. La vision par ordinateur utilise des techniques de traitement d'image pour extraire des descripteurs des images numériques en vue de la réalisation de différentes tâches, telles que la segmentation d'image et la reconnaissance d'objets ou de visages. Une fois ces informations acquises, elles peuvent ensuite être utilisées pour élaborer des décisions ou interagir avec l'environnement. Les applications de la vision par ordinateur sont nombreuses et diverses. Elle est utilisée dans des domaines tels que la reconnaissance faciale, la sécurité, la médecine, la surveillance, la robotique, la réalité augmentée, les jeux vidéo, la cartographie, la photographie et bien plus encore. De nombreuses techniques et algorithmes sont conçus pour la mise en œuvre de la vision par ordinateur, tels que l'apprentissage en profondeur, la reconnaissance de formes, l'analyse de texture et beaucoup d'autres. Citons aussi des bibliothèques logicielles comme OpenCV, TensorFlow, PyTorch et Scikit-image. La vision par ordinateur est un domaine en constante évolution ainsi qu'une expansion devenant omniprésente dans notre monde moderne. En effet, la révolution dans l'apprentissage en profondeur et les réseaux de neurones convolutifs a considérablement amélioré les performances relatives aux systèmes de vision par ordinateur.

3 Définition de l'analyse d'image et ses divers niveaux

L'analyse d'images désigne un processus d'extraction d'informations pertinentes et significatives des images numériques par l'application de techniques, citons la segmentation d'images, l'extraction de caractéristiques et la classification. En effet, ceci s'effectue suite à l'utilisation de méthodes mathématiques et statistiques dans le but d'identifier des modèles. L'analyse d'images est utilisée en médecine pour analyser des images médicales telles que X-Rays, l'IRM et les CT scans pour diagnostiquer des maladies ou bien des affections. L'analyse d'image se compose de plusieurs étapes, notamment : prétraitement des images pour l'amélioration de la qualité d'image, la segmentation des images, l'extraction de caractéristiques et la reconnaissance des formes. Ces étapes s'effectuent suite à l'utilisation de techniques : détection des bords, reconnaissance d'objets, analyse des textures, Apprentissage automatique ou apprentissage profond

4 Les paradigmes de l'apprentissage automatique et l'apprentissage profond

L'apprentissage automatique (machine learning) et l'apprentissage profond (Deep learning) sont des domaines de l'intelligence artificielle permettant à des ordinateurs de créer des modèles à partir des données et de les appliquer par la suite pour prendre des décisions ou effectuer des tâches spécifiques. Nous allons citer des domaines où ces technologies ont été appliquées : reconnaissance de formes, traduction automatique, reconnaissance vocale, diagnostic médical, détection de fraude, reconnaissance de caractères et les prévisions météorologiques. Il est utile de mentionner que ces technologies sont devenues omniprésentes dans de nombreux domaines et continuent de se développer rapidement.

4.1 L'apprentissage automatique

L'apprentissage automatique consiste en un sous-domaine de l'intelligence artificielle visant à créer des algorithmes et des modèles capables d'apprendre à partir de données et d'en générer des prédictions en se basant sur ces données. L'ultime objectif de l'apprentissage automatique est de permettre aux ordinateurs d'apprendre et de s'améliorer automatiquement à partir de l'expérience acquise sans être explicitement programmées. En effet, les algorithmes d'apprentissage automatique utilisent des données pour apprendre à partir d'exemples et améliorer leurs performances. Nous distinguons divers types d'algorithmes d'apprentissage automatique, notamment l'apprentissage supervisé, l'apprentissage non supervisé et l'apprentissage par renforcement. Dans le premier type d'apprentissage supervisé, l'algorithme est formé sur un ensemble de données étiquetées où la sortie est connue, et l'objectif principal est d'apprendre à prédire une éventuelle sor-

tie correcte pour de nouvelles entrées jamais traitées auparavant. En contre partie, dans l'apprentissage non supervisé, l'algorithme fut formé sur un ensemble de données non étiquetées où l'objectif est d'en trouver des modèles. D'autre part, dans l'apprentissage par renforcement, l'algorithme apprend suite à des essais et des erreurs. En récapitulant, l'apprentissage automatique a de diverses applications dans plusieurs domaines, citons la santé, le marketing, l'agriculture etc. en effet, sa capacité à apprendre des données et à en générer des prédictions ou à prendre des décisions a le potentiel de transformer et d'améliorer nombreuses industries et influencer sur la vie en général.

Nous allons citer avec vous tous les algorithmes d'apprentissage automatique utilisés dans ce projet comme suit

4.1.1 Machines à Vecteurs de Support

Les machines à vecteurs de support (SVM) sont un algorithme incontournable utilisé dans l'apprentissage automatique pour les tâches de classification et de régression. Les SVM présentent un objectif de trouver le meilleur hyperplan qui sépare les données en différentes classes en prédictant une variable de sortie basée sur les caractéristiques d'entrée. Dans la classification binaire, le but de SVM est de trouver l'hyperplan qui sépare les deux classes avec une marge maximale, qui est la distance entre l'hyperplan et les points de données les plus proches de chaque classe. Les SVM sont aussi particulièrement utiles pour les problèmes non linéaires, où les données ne peuvent pas être séparées par une ligne droite. En effet, face à cette situation les SVM utilisent les fonctions noyau (kernel) pour amener les données à un espace de dimension supérieure où un hyperplan pourra être trouvé qui sépare convenablement les données. Nous présentons sur la figure I.1, un problème de classification à deux classes en haut avec une séparation linéaire et en bas avec une séparatrice non linéaire. Nous présentons sur la figure 6, un problème de classification à deux classes en haut avec une séparation linéaire et en bas avec une séparatrice non linéaire.




FIGURE 6 – Problème de classification à deux classes en haut avec une séparation linéaire et en bas avec une séparatrice non linéaire.

Les SVM présentent divers avantages pour les problèmes de classification et de régression :

1. Les SVM sont efficaces dans les espaces de grande dimension, ce qui est particulièrement utile lorsqu'il s'agit de grands ensembles de données.
2. Les SVM peuvent gérer des données non linéaires à l'aide de fonctions du noyau, ce qui les rend adaptées à un large éventail de problèmes.
3. Les SVM sont moins sujets à l'overfitting que les autres algorithmes, ce qui signifie qu'ils sont plus susceptibles du processus de généralisation à de nouvelles données.

Ceci dit, les SVM présentent aussi certaines limitations :

1. Sensibilité au choix de la fonction noyau et de ses paramètres, ce qui peut affecter leurs performances.
2. Les SVM peuvent être coûteuses en calcul surtout pour les grands ensembles de données.

4.1.2 Forêts aléatoires (Random Forest)

Les forêts aléatoires sont un ensemble d'arbres de décision entraînés sur des sous-ensembles aléatoires des données. - Elles sont robustes au bruit et aux données aberrantes, et permettent de gérer facilement les variables catégorielles et continue. Les forêts aléatoires sont très performantes pour la classification de données de télédétection

Un Random Forest nécessite trois hyper paramètres principaux, définis avant l'entraînement :

- 1-la taille des arbres, c'est-à-dire le nombre de nœuds maximal
- 2-le nombre d'arbres à utiliser
- 3-le nombre de caractéristiques échantillonnées.

Random Forest combine le concept de bagging (pour bootstrap aggregating) avec des arbres de décision. Cela lui permet de générer un ensemble de modèles prédictifs diversifié et solide. Cet algorithme s'applique autant pour des tâches de régression que de classification.

Bagging (Bootstrap Aggregating) Il s'agit d'une technique de rééchantillonnage avec remplacement. Pour former chaque arbre décisionnel individuel dans la forêt, un échantillon aléatoire avec remplacement est prélevé à partir du jeu de données d'entraînement originel. Cette technique va permettre de créer plusieurs jeux d'entraînement différents. Ainsi, chacun des arbres est formé sur un dataset légèrement différent. C'est cette diversité dans les ensembles de données d'entraînement qui va contribuer à la variabilité des arbres.

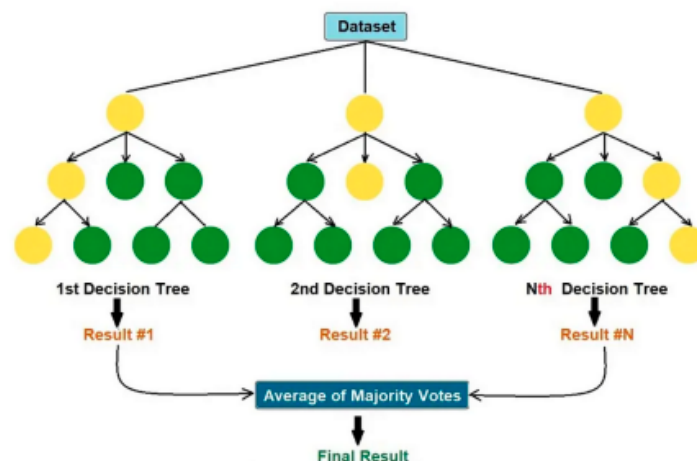


FIGURE 7 – Exemple de la structure d'un arbre de décision.

4.1.3 XGBoostClassifier(XGBClassifier)

Est un algorithme de boosting très performant basé sur la méthode de gradient boosting. Il se distingue par son efficacité, sa rapidité et sa capacité à gérer de grandes quantités de données tout en minimisant les erreurs de généralisation. XGBoost utilise des arbres de décision comme classificateurs de base et incorpore des techniques avancées comme la régularisation L1 et L2 pour prévenir l'overfitting. Cet algorithme est particulièrement apprécié dans les compétitions de data science pour sa capacité à améliorer les performances des modèles de manière significative.



FIGURE 8 – Exemple de XGBoostClassifier.

4.2 L'apprentissage profond

L'apprentissage en profondeur est considéré comme un sous-domaine de l'apprentissage automatique. Il est basé sur les réseaux de neurones artificiels avec plusieurs couches d'abstraction durant lesquelles il apprend des représentations de données. En effet, ces réseaux de neurones peuvent être composés de milliers ou aller jusqu'à des millions de nœuds de traitement interconnectés fonctionnant ensemble pour la reconnaissance de modèles, en générer des prédictions ainsi que de nouvelles informations à partir d'ensembles de données complexes. La caractéristique la plus surprenante de l'apprentissage en profondeur est sa capacité d'extraire automatiquement des descripteurs de haut niveau à partir de données brutes, telles que des images, des signaux vocaux ou encore du texte. Ceci, sans se diriger vers le besoin d'une ingénierie manuelle des descripteurs. Cela fait la particularité de l'apprentissage en profondeur où il s'est avéré très efficace dans des applications où les données sont complexes ou bien mal comprises, telles que la découverte de médicaments. L'apprentissage en profondeur a fait ravage dans un large éventail de domaines, citons : la vision par ordinateur, l'analyse de l'image médicale, la reconnaissance vocale, le traitement du langage naturel et la robotique. Il est utile de mentionner que les avènements récents de la puissance du matériel, tels que les unités de traitement graphique (GPU), ont favorisé la formation de réseaux de neurones plus approfondis et complexes à la fois, engendrant des performances davantage plus impressionnantes dans diverses applications.

4.2.1 Les réseaux de neurones convolutifs (CNN)

Les réseaux de neurones convolutifs, ou CNN, sont une classe de réseaux neuronaux spécialement conçus pour le traitement des données structurées sous forme d'images.

Ils se distinguent par leur capacité à extraire automatiquement les caractéristiques pertinentes des images, ce qui les rend très efficaces pour les tâches de vision par ordinateur. Voici les principales composantes et avantages des CNN :




FIGURE 9 – Architecture d'un réseaux de neurones convolutifs .

Architecture :

Un CNN se compose de plusieurs types de couches organisées pour transformer les données d'entrée en sorties pertinentes.

1-Entrées : Les entrées d'un CNN sont généralement des images, qui sont représentées sous forme de matrices de pixels. Chaque pixel d'une image est associé à une valeur de couleur, qui peut être exprimée en niveaux de gris ou en valeurs RGB (rouge, vert, bleu). Ces images sont souvent normalisées pour améliorer la performance du modèle.

2. Les couches cachées : sont constituées de différentes couches spécialisées, chacune jouant un rôle crucial dans l'extraction des caractéristiques. Voici les principales types de couches :

- **Couches convolutives :** ces couches appliquent des filtres (ou noyaux) pour extraire les caractéristiques locales de l'image. Les filtres glissent sur l'image et effectuent des opérations de convolution, produisant ainsi des cartes de caractéristiques (feature maps) qui mettent en évidence des motifs spécifiques, tels que des contours ou des textures.




FIGURE 10 – Couches convolutives.

- **Couches de pooling** : Les couches de pooling, également appelées couches de sous-échantillonnage, sont utilisées pour réduire la dimensionnalité des cartes de caractéristiques tout en conservant les informations essentielles. Cela se fait généralement par des opérations comme le max pooling, qui prend la valeur maximale dans une fenêtre définie (par exemple, 2x2 pixels) et réduit ainsi la taille de l'image.



FIGURE 11 – Couches de pooling.

- **Couches Entièrement Connectées (Fully Connected Layers)** : Les couches entièrement connectées, qui se trouvent généralement à la fin d'un CNN, sont des couches où chaque neurone est connecté à tous les neurones de la couche précédente. Elles agissent comme un classificateur, prenant les cartes de caractéristiques résultantes des couches précédentes et les transformant en une prédiction finale.




FIGURE 12 – Couches Entièrement Connectées.

3. Sorties : Les sorties d'un CNN correspondent aux prédictions du modèle pour chaque classe de tumeur. En fonction de l'application, ces sorties peuvent être des probabilités associées à chaque classe ou des masques segmentés pour les tâches de segmentation.

4.3 Description de quelques modèles des réseaux de neurone convolutifs

4.3.1 EfficientNet50 :

EfficientNet est une famille de réseaux de neurones convolutifs . Ces modèles ont été conçus dans le but d'atteindre un équilibre optimal entre précision et efficacité. Contrairement aux approches classiques qui augmentent de manière unidimensionnelle la profondeur, la largeur ou la résolution d'entrée, EfficientNet propose une stratégie appelée "compound scaling", qui augmente ces trois dimensions de façon coordonnée. Cela permet d'obtenir des modèles à la fois puissants, légers et rapides à entraîner, tout en conservant une excellente capacité de généralisation.




FIGURE 13 – Architecture générale d'EfficientNet.

1-Entrée : Comme tout CNN, EfficientNet reçoit en entrée une image (généralement de taille 224×224 pour B0) représentée sous forme de matrice de pixels RGB. Ces images sont normalisées et redimensionnées avant d'être traitées.

2-Couches principales : Les couches d'EfficientNet sont structurées autour de blocs MBConv et de convolutions groupées optimisées :

- **Convolution initiale :** Une première couche de convolution est appliquée pour extraire les premières caractéristiques.
- **Blocs MBConv :** Ce sont des blocs inversés avec des connexions résiduelles, combinant :
 - Une expansion du nombre de canaux
 - Une convolution depthwise (spatiale mais par canal)
 - Une réduction (projection) du nombre de canaux
 - Et une connexion résiduelle si la dimension le permet.
- **Couches de normalisation et activation :** Chaque bloc est accompagné d'une normalisation (BatchNorm) et d'une fonction d'activation Swish, plus performante que ReLU
- **Couches finales :**
 - Une couche de Global Average Pooling pour résumer l'information spatiale.
 - Une couche entièrement connectée (dense) pour effectuer la prédiction finale selon les classes ciblées.
 - Une fonction softmax pour produire des probabilités.

4.3.2 ResNet50

ResNet50(Residual Network 50) est un modèle de réseau de neurones convolutifs (CNN) qui fait partie de la famille des réseaux résiduels (Residual Networks). Développé par Microsoft pour le concours ImageNet Large Scale Visual Recognition Challenge (ILSVRC) de 2015, ResNet50 se distingue par son utilisation des blocs résiduels, une innovation qui permet d'entraîner des réseaux très profonds sans souffrir du problème de la dégradation des gradients. ResNet50 comporte 50 couches pondérées et utilise des connexions "skip" ou "shortcut" pour permettre aux gradients de se propager plus faci-

lement à travers le réseau lors de l'entraînement, améliorant ainsi les performances des réseaux profonds




FIGURE 14 – Architecture générale de ResNet50 .

-Avantages de ResNet50 :

- **Profondeur Sans Dégradation des Performances :** L'architecture résiduelle permet de créer des réseaux très profonds tout en maintenant l'efficacité de l'entraînement grâce aux connexions résiduelles qui atténuent le problème de la disparition ou de l'explosion des gradients.
- **Excellente Précision :** ResNet50 a montré une précision élevée sur des tâches de classification d'images, se classant parmi les meilleurs modèles sur des benchmarks tels qu'ImageNet.
- **Transfert d'Apprentissage Efficace :** ResNet50 est largement utilisé comme modèle pré-entraîné pour le transfert d'apprentissage, étant donné sa capacité à extraire des caractéristiques générales efficaces à partir des images

-Inconvénients de ResNet50 :

- **Complexité Computationnelle :** Bien que ResNet50 soit plus efficace que des modèles similaires en termes de profondeur, il reste coûteux en termes de calcul et de mémoire, ce qui peut limiter son utilisation sur des appareils avec des ressources limitées.
- **Temps d'Entraînement Long :** Comme avec d'autres réseaux profonds, l'entraînement de ResNet50 peut prendre beaucoup de temps et nécessiter des ressources matérielles importantes, notamment des GPU de haute performance.

4.3.3 Modèle VGG16

C'est un modèle de réseau neuronal convolutif proposé par K. Simonyan et A. Zisserman de l'Université d'Oxford dans l'article « Very Deep Convolutional Networks for Large-Scale Image Recognition ». Le modèle atteint une précision de test de 92.7% dans le top 5 sur ImageNet, qui est un ensemble de données de plus de 14 millions d'images appartenant à 1000 classes. C'était l'un des modèles célèbres soumis à l'ILSVRC-2014. Il apporte une amélioration par rapport à AlexNet en remplaçant les grands filtres de la taille d'un noyau (11 et 5 dans la première et la deuxième couche convolutive, respectivement) par plusieurs filtres de la taille d'un noyau 3×3 l'un après l'autre. VGG16 a été

entraîné pendant des semaines et utilisait des GPU NVIDIA Titan Black. La figure 15 représente l'architecture du modèle VGG16.




FIGURE 15 – L'architecture du modèle VGG16.

5 Conclusion

Dans ce chapitre, nous avons exploré les différentes formes d'apprentissage utilisées en intelligence artificielle, notamment l'apprentissage supervisé, non supervisé et par renforcement. Chacune de ces approches apporte des solutions adaptées à des problématiques spécifiques, qu'il s'agisse de prédiction, de regroupement de données ou d'apprentissage par interaction avec l'environnement.

Nous avons ensuite détaillé les principaux algorithmes d'apprentissage automatique exploités dans ce projet, tels que les Machines à Vecteurs de Support (SVM), les Forêts Aléatoires (Random Forest) et XGBoost, en mettant en évidence leurs mécanismes, avantages et limites. Ces modèles ont démontré leur efficacité dans des tâches complexes de classification, particulièrement dans le traitement de données médicales.

Enfin, une attention particulière a été accordée à l'apprentissage profond, en particulier aux réseaux de neurones convolutifs (CNN), ainsi qu'aux architectures avancées comme EfficientNet50, ResNet50 et VGG16, qui ont largement prouvé leur performance en vision par ordinateur. Leur capacité à extraire automatiquement des caractéristiques pertinentes à partir d'images médicales les rend particulièrement adaptés à notre problématique.

Ces techniques constituent ainsi une base solide pour le développement de solutions intelligentes en santé, et posent les fondations méthodologiques du travail que nous présenterons dans les chapitres suivants.

Chapitre 3 : Méthodologie, implémentation et résultats

1 Introduction

Dans cette section, nous présentons en détail les méthodes et les algorithmes adoptés dans le cadre de notre approche de classification des images IRM du cerveau. Afin de valider la performance de notre système, nous avons mené une série d'expériences contrôlées en utilisant le langage Python, en évaluant les résultats à l'aide de métriques standards telles que l'exactitude, la précision, le rappel et la mesure F1-score.

Deux types de classification ont été explorés dans ce travail :

-Classification binaire : visant à distinguer les images IRM présentant une tumeur cérébrale de celles représentant un cerveau sain. Pour cette tâche, nous avons comparé plusieurs algorithmes d'apprentissage automatique et d'apprentissage profond, notamment : Random Forest, SVM, XGBoost, un CNN conventionnel, ainsi que des modèles préentraînés tels que ResNet50 et EfficientNet.

-Classification multi-classe : consistant à identifier le type de tumeur parmi quatre catégories : gliome, méningiome, tumeur de l'hypophyse et cerveau sain. Pour cette expérience, Nous avons évalué les performances des modèles VGG16, EfficientNet et ResNet50 dans un cadre de transfert d'apprentissage, appliqué à la classification multi-classe. Avant l'entraînement, les images ont été soumises à un prétraitement et à une augmentation pour en optimiser la qualité et renforcer la généralisation des modèles. Les données ont ensuite été soigneusement réparties en ensembles d'apprentissage, de validation et de test.

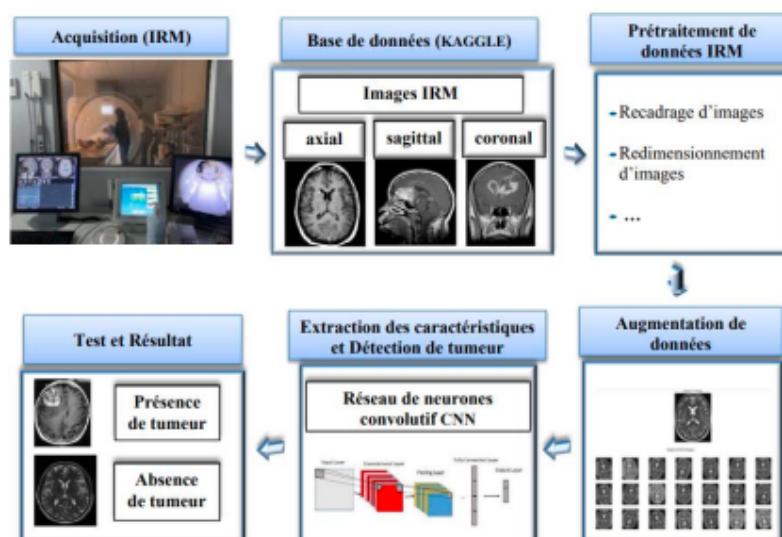


FIGURE 16 – le schéma fonctionnel de la méthode proposée.

La FIGURE 16 montre le schéma fonctionnel de la méthode proposée, dans laquelle le

système commence à charger et à extraire des images et des étiquettes à partir de fichiers bruts d'ensembles de données, puis à effectuer des techniques de prétraitement et d'augmentation juste après avoir divisé l'ensemble de données en ensembles d'apprentissage, de validation et de test. Ensuite, la structure de la méthode proposée est introduite, suivie de la définition des hyper-paramètres, des techniques de régularisation et de l'algorithme d'optimisation. Enfin, l'apprentissage du réseau et les calculs de performances sont présentés.

2 Environnement de travail :

2.1 Ressource matériel :

Ce travail a été effectué sur un ordinateur personnel doté des caractéristiques suivantes :

- **Processeur** : Intel Core i5 de 3e génération
- **Mémoire RAM** : 12 Go
- **Stockage** : Un disque dur SSD de 256 Go
- **Système d'exploitation** : Système d'exploitation 64 bits, processeur x64

2.2 Outils de programmation :

- **Python** : Python est un langage de programmation interprété, de haut niveau et multiplateforme. Il a été créé en 1989 par Guido van Rossum et est maintenant maintenu par une communauté mondiale de développeurs. Python est largement utilisé pour la programmation web, l'analyse de données, l'intelligence artificielle, l'automatisation des tâches et bien d'autres domaines. Il est connu pour sa syntaxe simple et facile à apprendre, ainsi que pour sa grande bibliothèque standard qui offre un large éventail de fonctionnalités pour les développeurs. Les bibliothèques les plus utilisées dans l'intelligence artificielle sont implémentées par Python, citons opencv et Scikit-learn, Pandas et bien beaucoup d'autres.



FIGURE 17 – Logo python

- **Colab** : Colab est un environnement de développement collaboratif basé sur le cloud, offert gratuitement par Google. Il permet d'exécuter du code Python directement dans le navigateur, sans nécessiter de configuration ou d'installation

complexe. Colab offre un accès aux ressources de calcul, y compris les GPU et les TPU, et facilite le partage et la collaboration grâce à la création de cahiers interactifs.



FIGURE 18 – Logo Colab

- **Streamlit** : est un framework open-source en Python conçu pour créer rapidement et facilement des applications web interactives destinées à la visualisation et à l'exploration de données. Il permet aux data scientists et ingénieurs en machine learning de transformer leurs scripts Python en tableaux de bord web en quelques lignes de code, sans nécessiter de compétences avancées en développement web.



FIGURE 19 – Logo Streamlit

- **Visual Studio Code (VS Code)** : est un éditeur de code source léger, multi-plateforme et open-source développé par Microsoft. Il est largement utilisé dans le développement logiciel grâce à sa rapidité, son interface intuitive et ses nombreuses extensions. Il prend en charge plusieurs langages de programmation, dont Python, et offre des fonctionnalités avancées telles que l'autocomplétion, le débogage intégré, le contrôle de version Git et la personnalisation de l'environnement de développement.




FIGURE 20 – Logo Visual Studio Code

2.3 Bibliothèques utilisées :

- **NumPy** : Utilisée pour la manipulation de tableaux et de matrices, ainsi que pour les opérations mathématiques avancées.
- **matplotlib** : Utilisée pour la visualisation des données et l’affichage de graphiques, facilitant ainsi l’analyse des résultats.
- **Os** : Utilisée pour interagir avec le système d’exploitation, notamment pour la manipulation de fichiers et de répertoires.
- **seaborn** : Utilisée pour des visualisations statistiques avancées et des graphiques attrayants.
- **OpenCV** : Utilisés pour le traitement et la manipulation des images
- **TensorFlow et Keras** : Utilisés pour la construction et l’entraînement des modèles de CNN et de transfert d’apprentissage.
- **scikit-learn** : Utilisé pour l’évaluation des modèles et la génération de rapports de classification, matrices de confusion et courbes ROC.
- **time** : Utilisée pour manipuler le temps, par exemple pour mesurer la durée d’exécution de certaines opérations.

3 Les techniques de préparation des données :

Dans les sections suivantes, je détaillerai les différentes techniques que j’ai appliquées pour préparer les données utilisées dans ce projet, en soulignant leur importance et leur contribution à la performance globale des modèles.

3.1 Recadrage des images

Le recadrage des images est une des premières étapes dans la préparation des données. Cette technique permet de réduire les zones inutiles et de se concentrer sur la région d’intérêt, à savoir le cerveau. Pour ce faire, j’ai utilisé la bibliothèque OpenCV, qui offre des outils performants pour le traitement des images. Les étapes suivies pour le recadrage sont les suivantes :

- **Conversion en niveaux de gris** : Les images couleurs sont converties en niveaux de gris afin de simplifier les opérations tout en conservant les informations nécessaires pour identifier les contours.
- **Application d’un seuillage** : Un seuil binaire est appliqué pour isoler les zones les plus significatives, ce qui met en évidence les limites du cerveau dans l’image.
- **Détection des contours** : J’ai utilisé la méthode `findContours` pour détecter les contours dans l’image. Parmi les contours identifiés, j’ai sélectionné le plus grand contour correspondant à la forme générale du cerveau.

- **Recadrage** : A partir du contour identifié, l'image est recadrée pour ne conserver que la région contenant le cerveau, éliminant ainsi les espaces vides et les bruits de fond.

Voici un exemple d'une image recadrée :




FIGURE 21 – Illustration d'une image recadrée

3.2 Redimensionnement

Après le recadrage, je procède au redimensionnement des images. La plupart des images présentes dans le jeu de données ont une haute résolution de 512x512 pixels, mais cette résolution peut entraîner des temps de traitement plus longs et une consommation de mémoire plus importante. Cette figure montre les dimensions les plus fréquentes des images dans l'ensemble d'entraînement. Pour optimiser les performances du modèle tout

```
Pré-traitement terminé !
Forme de X: (5619, 224, 224, 1)
Forme de y: (5619,)
```

FIGURE 22 – les Tailles d'images les plus fréquentes

en conservant une qualité d' image adéquate, j'ai choisi de redimensionner les images à une résolution de 224x224 pixels. Cette taille permet de réduire les exigences en mémoire tout en préservant les détails nécessaires à la classification des tumeurs

3.3 Normalisation

Pour garantir que les valeurs des pixels soient dans une plage standardisée, j'utilise la fonction `normalize()` de la bibliothèque OpenCV. En utilisant la méthode NORM MIN-MAX, je normalise les valeurs des pixels pour qu'elles se situent généralement entre 0 et 1.

Cela permet d'homogénéiser les données d'entrée, facilitant ainsi l'apprentissage des modèles. En réglant les paramètres alpha à 0 et beta à 1, j'ai pu m'assurer que les images sont normalisées de manière uniforme, ce qui améliore la convergence lors de l'entraînement des modèles. La formule s'écrit comme suit :

$$\text{valeur normalisée} = \left(\frac{x - \min(x)}{\max(x) - \min(x)} \right) \times (\beta - \alpha) + \alpha$$

ou :

- x est la valeur actuelle de l'élément que vous souhaitez normaliser.
- $\min(x)$ est la valeur minimale de l'ensemble de données.
- $\max(x)$ est la valeur maximale de l'ensemble de données.
- α est la nouvelle valeur minimale (par exemple, 0 dans la plage $[0, 1]$).
- β est la nouvelle valeur maximale (par exemple, 1 dans la plage $[0, 1]$).

3.4 Mélanger les données

Avant de diviser les données en ensembles d'entraînement et de validation, il est essentiel de mélanger les données. J'ai utilisé la fonction `shuffle()` pour mélanger l'ensemble de données, garantissant que le modèle ne soit pas biaisé par l'ordre initial des images, qui pourrait être regroupé par classe. Le mélange permet d'éviter que le modèle apprenne des tendances spécifiques à l'ordre des données et favorise une généralisation plus robuste lors de l'évaluation avec de nouvelles données.

3.5 Division des données

La division de l'ensemble de données en ensembles d'entraînement et de test est une étape cruciale pour évaluer la performance du modèle. J'ai utilisé la fonction `train_test_split` pour diviser l'ensemble d'entraînement avec une proportion de 80 % pour l'entraînement et 20 % pour le test. De plus, j'ai également divisé l'ensemble de test en ensembles de validation et de test, en utilisant la même fonction avec une proportion de 50 % pour chaque sous-ensemble. Cette approche me permet de valider le modèle sur des données qu'il n'a pas encore vues, ce qui est essentiel pour évaluer sa capacité à généraliser.

Ci-dessous est la visualisation de la répartition des images après la division




FIGURE 23 – Division des données

3.6 Encodage One-Hot

Pour traiter les étiquettes de classification, j'ai appliqué un encodage OneHot en utilisant la méthode `to categorical()`. Cette transformation est essentielle pour le prétraitement des étiquettes, car elle convertit chaque classe en une représentation binaire.

Chaque classe est ainsi représentée par un vecteur où un seul bit est activé pour la classe correspondante, tandis que les autres bits sont désactivés. Cela permet au modèle de gérer efficacement les classes catégoriques lors de l'entraînement et d'améliorer la précision des prédictions.




FIGURE 24 – Encodage One-Hot

3.7 Augmentation des données

L'augmentation des données est essentielle pour renforcer la robustesse des modèles d'apprentissage profond. En appliquant des transformations aléatoires telles que la rotation, le cisaillement, le zoom et le retournement horizontal, j'ai généré de nouvelles données à partir des images existantes, enrichissant ainsi l'ensemble d'entraînement et diversifiant les conditions d'entrée. Un exemple illustre une image augmentée à quatre reprises




FIGURE 25 – Augmentation des données

4 Mesures de performance utilisées :

Après avoir implémenté le modèle et obtenu des résultats en classe ou probabilité, l'étape suivante consiste à évaluer son efficacité à l'aide de diverses métriques sur des ensembles de données de test. Certaines mesures de performance sont utilisées pour spécifier divers algorithmes d'apprentissage automatique. Le choix de la bonne métrique est crucial car il influence directement les performances de l'algorithme.

4.1 Matrice de Confusion :

Une matrice de confusion est une matrice utilisée pour évaluer les performances d'un modèle de classification en comparant les prédictions du modèle avec les vraies valeurs. Elle est souvent utilisée en apprentissage automatique pour évaluer la qualité d'un modèle de classification, qu'ils soient binaires (prédiction de deux classes) ou multi-classes (prédiction de plusieurs classes). La matrice de confusion se compose de quatre éléments : les vrais positifs (TP), les faux positifs (FP), les vrais négatifs (TN) et les faux négatifs (FN).

| | | Actual Values | |
|------------------|--------------|---------------|--------------|
| | | Positive (1) | Negative (0) |
| Predicted Values | Positive (1) | TP | FP |
| | Negative (0) | FN | TN |

FIGURE 26 – La matrice de confusion.

4.2 Précision de la classification (Accuracy) :

L'accuracy (précision globale) est une métrique d'évaluation couramment utilisée pour mesurer la performance globale d'un modèle de classification. Elle représente le taux de prédictions correctes (vrais positifs et vrais négatifs) par rapport au nombre total d'échantillons dans l'ensemble de données. En d'autres termes, l'exactitude évalue la proportion de prédictions correctes parmi toutes les prédictions effectuées par le modèle.

La formule de l'accuracy est la suivante :

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1.1)$$

4.3 Précision (Precision) :

La précision mesure la proportion des prédictions positives effectuées par un modèle qui sont réellement correctes. En d'autres termes, elle indique combien de prédictions positives sont pertinentes parmi toutes les prédictions positives.

La formule de la précision est la suivante :

$$\text{Précision} = \frac{TP}{TP + FP} \quad (1.2)$$

4.4 Rappel (Recall) :

Le rappel, également appelé sensibilité ou taux de vrais positifs, mesure la proportion des instances positives réellement correctement prédites par le modèle parmi toutes les instances positives réelles. Le rappel indique donc combien de prédictions positives pertinentes ont été capturées.

La formule du rappel est la suivante :

$$\text{Recall} = \frac{TP}{TP + FN} \quad (1.3)$$

4.5 F-mesure (F1-score) :

La F-mesure est une métrique qui combine à la fois la précision et le rappel en une seule valeur pour donner une vue globale des performances d'un modèle. Elle est particulièrement utile lorsque les classes ne sont pas équilibrées. La F-mesure prend en compte à la fois les faux positifs et les faux négatifs, ce qui la rend utile pour évaluer les performances globales d'un modèle de classification.

La formule du F-mesure est la suivante :

$$\text{F-mesure} = \frac{2 \times (\text{Précision} \times \text{Recall})}{\text{Précision} + \text{Recall}} \quad (1.4)$$

5 Application1 : Classification Binaire

Dans cette expérience, nous avons classé les images IRM cérébrales en deux catégories : les images avec tumeur et les images sans tumeur cérébrale (saines). Pour ce faire, plusieurs modèles ont été utilisés, incluant des algorithmes classiques comme les forêts aléatoires (Random Forest), les machines à vecteurs de support (SVM) et XGBoost, ainsi que des modèles de réseaux de neurones convolutifs (CNN), comprenant un CNN conventionnel, ResNet50 et EfficientNet. Ces modèles permettent à la fois une bonne extraction des caractéristiques et une performance robuste dans la classification binaire.

5.1 Acquisition de la base de données

L'ensemble de données utilisé pour la formation et les tests a été collecté auprès de Kaggle. Il contient des images d'IRM cérébrales dans lesquelles certaines d'entre elles sont des images contenant une tumeur (images tumorales) et certaines images sont normales (sans tumeur). Les images tumorales sont séparées dans le dossier nommé 'Tumeur cérébrale' et les images normales sont conservées dans le dossier "sain". Les images sont de différents formats et de tailles variables.

5.2 Modèles proposes

Avant l'entraînement, l'ensemble de données a été divisé en trois sous-ensembles : 70% pour l'entraînement, 15% pour la validation et 15% pour le test, afin d'assurer une évaluation rigoureuse du modèle. Les images ont ensuite été augmentées et redimensionnées à une taille standard de 224×224 pixels avec 3 canaux RGB. Pour améliorer la performance et éviter le surapprentissage, des techniques comme le dropout et l'early stopping ont été appliquées. De plus, une réduction de dimensionnalité par ACP (PCA) a été utilisée pour accélérer l'entraînement des modèles classiques, dont les hyperparamètres ont été optimisés via une recherche systématique. Le modèle CNN a été construit avec plusieurs couches convolutives, normalisation par batch, pooling, et couches denses, compilé avec une fonction de perte adaptée, et entraîné avec des mécanismes pour optimiser la généralisation.

5.2.1 Random Forest

Afin d'évaluer les performances du modèle, nous présentons ci-dessous le rapport de classification ainsi que la matrice de confusion correspondante. Ces visualisations permettent de mieux comprendre la qualité des prédictions effectuées par le modèle

Visualisation des résultats du modèle

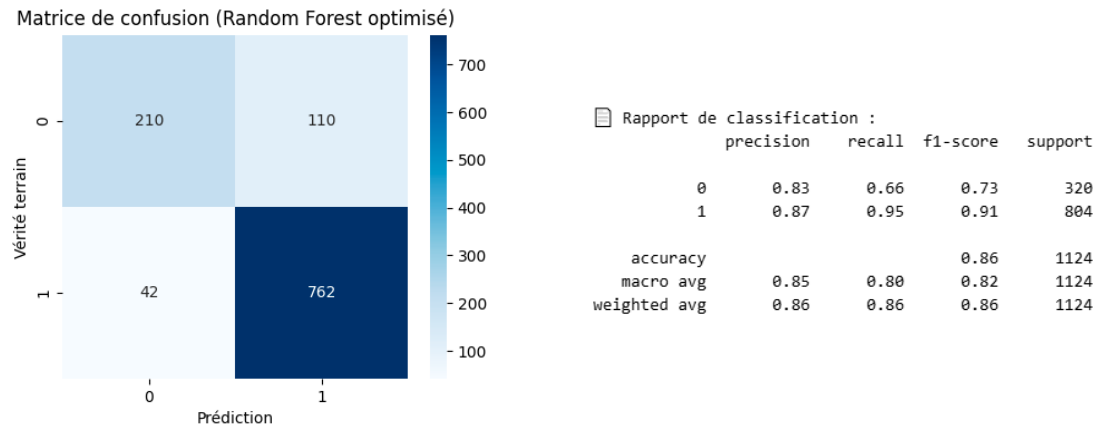


FIGURE 27 – Matrice de confusion et rapport de classification du Random Forest.

La matrice de confusion présentée ci-dessus illustre les performances du modèle Random Forest optimisé sur l'ensemble de test. On observe que le modèle identifie correctement la majorité des images avec et sans tumeur, avec 210 vrais négatifs et 762 vrais positifs. Les faux positifs (110) et faux négatifs (42) restent relativement faibles, indiquant une bonne capacité de généralisation. Le rapport de classification confirme ces résultats avec une précision moyenne pondérée de 0.86, un rappel global de 0.86 et un score F1 de 0.86, traduisant un bon équilibre entre précision et sensibilité pour les deux classes.

5.2.2 Support Vector Machine (SVM)

Dans cette expérience, un classificateur Support Vector Machine (SVM) a été entraîné pour détecter la présence de tumeurs cérébrales sur des images IRM. Afin de maximiser les performances, nous avons combiné une normalisation des données, une réduction de dimension par PCA et une recherche des meilleurs hyperparamètres via GridSearchCV.

Visualisation des résultats du modèle




FIGURE 28 – Support Vector Machine (SVM).

Le modèle final a atteint une exactitude (accuracy) de 94% et un score AUC de 0.9794,

indiquant une excellente performance en classification binaire. Le rapport de classification montre un bon équilibre entre précision et rappel, avec un faible taux d'erreurs. Ces résultats suggèrent que le SVM, associé à une bonne préparation des données, est un choix pertinent pour ce type de tâche.

5.2.3 XGBoost (Extreme Gradient Boosting)

Pour cette expérimentation, nous avons utilisé le modèle XGBoost, une méthode de boosting basée sur des arbres de décision. Grâce à sa régularisation intégrée et à sa capacité à gérer des données complexes, XGBoost est reconnu pour sa robustesse et sa précision. Après avoir standardisé les données d'entrée, le modèle a été entraîné avec des hyperparamètres classiques (nestimators=100, maxdepth=3, learningrate=0.1).

Visualisation des résultats du modèle

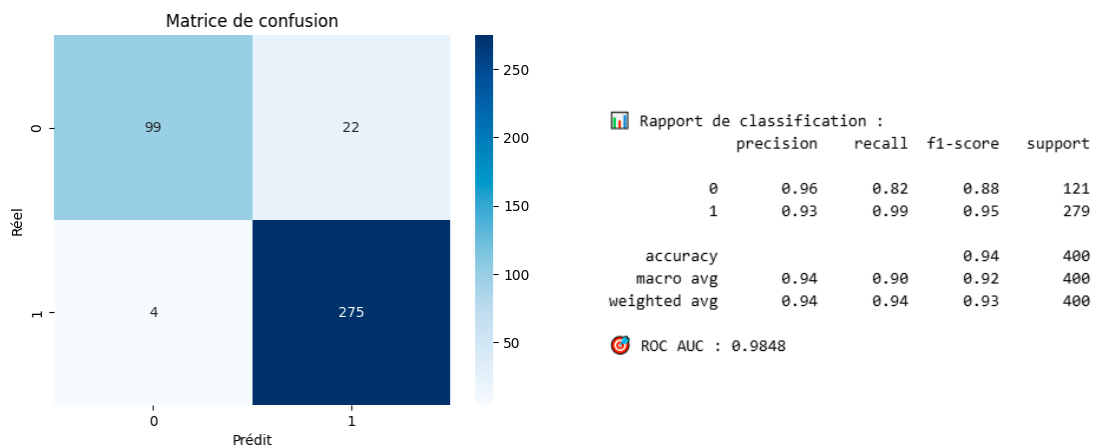


FIGURE 29 – XGBoost (Extreme Gradient Boosting).

Le modèle XGBoost a démontré une excellente performance avec une précision globale de 94% et un score ROC AUC de 0.9848. La matrice de confusion et le rapport de classification montrent une très bonne capacité du modèle à détecter les deux classes, notamment un rappel élevé de 99% pour les cas positifs (présence de tumeur), ce qui est crucial dans un contexte médical.

5.2.4 Réseau neuronal convolutionnel (CNN)

Pour la détection des tumeurs cérébrales, nous avons conçu un réseau neuronal convolutionnel (CNN) personnalisé, composé de plusieurs couches convolutives, de normalisation par lot, de sous-échantillonnage, et d'une couche dense finale avec une activation softmax. Ce modèle a été entraîné sur des images IRM redimensionnées et normalisées, avec des techniques de régularisation telles que Dropout et EarlyStopping pour éviter le surapprentissage.

| Paramètre | Valeur |
|------------------|--------|
| Learning Rate | 0.0001 |
| Batch Size | 32 |
| Nombre d'Époques | 30 |
| Training Size | 70% |
| Optimiseur | Adam |

TABLE 1.2 – Paramètres d'entraînement du modèle CNN personnalisé.

Visualisation des résultats du modèle




FIGURE 30 – Réseau neuronal convolutionnel (CNN).

Le modèle démontre d'excellentes performances globales avec une précision de 0,96 pour la classe "Sans tumeur" et un rappel de 0,92, ce qui indique une capacité élevée à éviter les faux positifs. Pour la classe "Avec tumeur", la précision atteint 0,97 et le rappel 0,98, soulignant une très bonne capacité de détection des cas tumoraux avec un très faible taux de faux négatifs. Les scores F1 équilibrés (0,94 pour "Sans tumeur" et 0,98 pour "Avec tumeur") traduisent une robustesse remarquable du modèle sur les deux classes.

courbes d'apprentissage

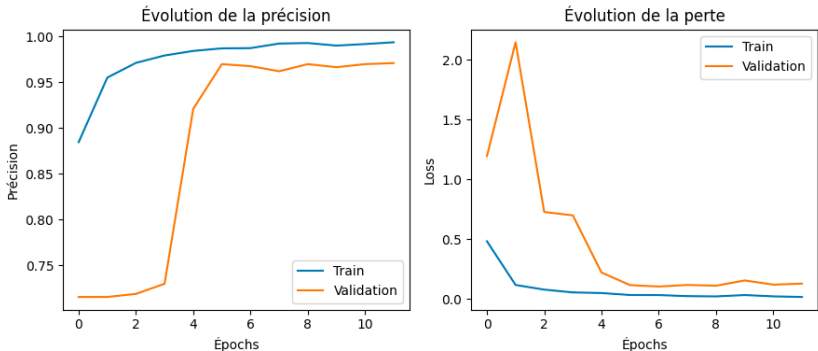


FIGURE 31 – Learning Curve (CNN)

Les courbes d'apprentissage ci-dessous illustrent une progression régulière du modèle

au fil des époques. La précision augmente rapidement dès les premières itérations, atteignant près de 0,98 en entraînement et en validation. Parallèlement, la perte diminue de manière significative, ce qui traduit une amélioration de la capacité du modèle à minimiser l'erreur. L'absence d'écart important entre les courbes d'entraînement et de validation suggère que le modèle généralise bien sans surapprentissage notable. Ces résultats confirment l'efficacité du modèle CNN personnalisé pour la classification binaire des images IRM cérébrales.

| Indicateur | Valeur approximative |
|------------------------|----------------------|
| Précision entraînement | 0.99 |
| Précision validation | 0.97 |
| Perte entraînement | ≈ 0.01 |
| Perte validation | ≈ 0.15 |
| Nombre d'époques | 11 |
| Signe d'overfitting | Non observé |

TABLE 1.3 – Résumé des performances d'apprentissage du modèle CNN.

5.2.5 ResNet101

Pour affiner davantage la détection des tumeurs cérébrales, nous avons exploité la puissance du modèle pré-entraîné ResNet101, réputé pour sa profondeur et sa capacité à extraire des caractéristiques complexes. Ce modèle a été adapté à notre tâche en ajoutant une tête personnalisée composée de couches de GlobalAveragePooling, Dropout et Dense avec activation sigmoïde pour la classification binaire. Les couches du modèle de base ont été gelées afin de préserver les poids issus d'ImageNet. L'apprentissage a été optimisé grâce à des techniques comme l'augmentation de données, EarlyStopping, et ModelCheckpoint, ce qui a permis d'améliorer la robustesse et d'éviter le surapprentissage.

| Paramètre | Valeur |
|-------------------------|---------------------------------|
| Architecture | ResNet101 pré-entraîné |
| Taille d'entrée | $224 \times 224 \times 3$ |
| Learning Rate | 0.0001 |
| Batch Size | 32 |
| Nombre d'Époques | 30 |
| Optimiseur | Adam |
| Fonction de perte | Binary Crossentropy |
| Augmentation de données | Rotation, zoom, flip horizontal |
| Régularisation | Dropout (0.5 et 0.3) |

TABLE 1.4 – Paramètres d'entraînement du modèle ResNet101 personnalisé.

Visualisation des résultats du modèle




FIGURE 32 – ResNet101.

Le modèle basé sur ResNet101 présente des performances globales satisfaisantes, avec une précision de 0,81 pour les deux classes. Toutefois, on observe un déséquilibre notable entre les rappels : 0,95 pour la classe "Avec tumeur", indiquant une excellente capacité de détection des cas tumoraux, contre seulement 0,49 pour la classe "Sans tumeur", suggérant un taux plus élevé de faux positifs. Les scores F1 de 0,88 pour "Avec tumeur" et 0,61 pour "Sans tumeur" reflètent cette disparité. Malgré cela, l'exactitude globale atteint 0,81, traduisant une bonne performance générale, bien que perfectible pour équilibrer les deux classes.

courbes d'apprentissage




FIGURE 33 – Learning Curve ResNet101

Les courbes d'apprentissage ci-dessus montrent une amélioration constante des performances du modèle au fil des époques. La perte (loss) diminue progressivement aussi bien pour les données d'entraînement que de validation, ce qui indique une optimisation efficace de la fonction de coût. En parallèle, la précision (accuracy) connaît une augmentation continue, atteignant près de 0,79 pour l'entraînement et 0,83 pour la validation. Le fait que les courbes de validation restent proches de celles de l'entraînement, sans divergence marquée, suggère que le modèle ne souffre pas de surapprentissage et qu'il généralise bien sur des données non vues. Ces résultats témoignent d'un apprentissage stable et d'un bon compromis entre biais et variance.

| Indicateur | Valeur approximative |
|------------------------|----------------------|
| Précision entraînement | 0.80 |
| Précision validation | 0.83 |
| Perte entraînement | ≈ 0.49 |
| Perte validation | ≈ 0.43 |
| Nombre d'époques | 30 |
| Signe d'overfitting | Non observé |

TABLE 1.5 – Résumé des performances d'apprentissage du modèle ResNet101.

5.2.6 EfficientNetB0

Dans le cadre de notre étude, nous avons exploité le modèle pré-entraîné **EfficientNetB0** pour la classification binaire des images IRM cérébrales. Ce modèle, basé sur une architecture optimisée en termes de performance et de complexité, a été utilisé en tant que base convolutive, à laquelle nous avons ajouté un classifieur personnalisé composé de couches *GlobalAveragePooling2D*, *Dropout*, et *Dense*. L'entraînement a été effectué en deux étapes : une première phase avec la base gelée, suivie d'un *fine-tuning* où seules les couches profondes ont été réentraînées. Les données ont été augmentées par des transformations géométriques afin de renforcer la robustesse du modèle, et des techniques de régularisation comme *Dropout*, *EarlyStopping* et *ReduceLROnPlateau* ont été utilisées pour limiter le surapprentissage.

| Paramètre | Valeur |
|---------------------------------------|---|
| Architecture de base | EfficientNetB0 (pré-entraînée sur ImageNet) |
| Learning Rate (initial / fine-tuning) | 0.0001 / 0.00001 |
| Batch Size | 32 |
| Nombre d'Époques | 50 (pré-entraînement) + 30 (fine-tuning) |
| Taille des images | $224 \times 224 \times 3$ |
| Répartition des données | 60% entraînement, 20% validation, 20% test |
| Optimiseur | Adam |
| Régularisation | Dropout, EarlyStopping, ReduceLROnPlateau |

TABLE 1.6 – Paramètres d'entraînement du modèle EfficientNetB0.

Visualisation des résultats du modèle




FIGURE 34 – EfficientNetB0.

Le modèle basé sur EfficientNetB0 affiche de très bonnes performances globales avec une exactitude de 0,84, confirmant son efficacité pour la classification binaire des IRM cérébrales. La classe "Avec tumeur" est détectée avec une grande fiabilité, comme en témoignent un rappel de 0,96 et un score F1 de 0,90, traduisant une forte sensibilité aux cas positifs. En revanche, la classe "Sans tumeur" présente un rappel plus faible (0,57), indiquant un nombre non négligeable de faux positifs. Le score F1 de 0,67 pour cette classe met en évidence ce déséquilibre. Malgré cela, les valeurs de précision élevées dans les deux classes (0,83 et 0,85) témoignent d'une bonne capacité discriminante. Le modèle montre ainsi une bonne généralisation, bien qu'une attention particulière soit encore nécessaire pour améliorer la détection des cas sans tumeur.

courbes d'apprentissage

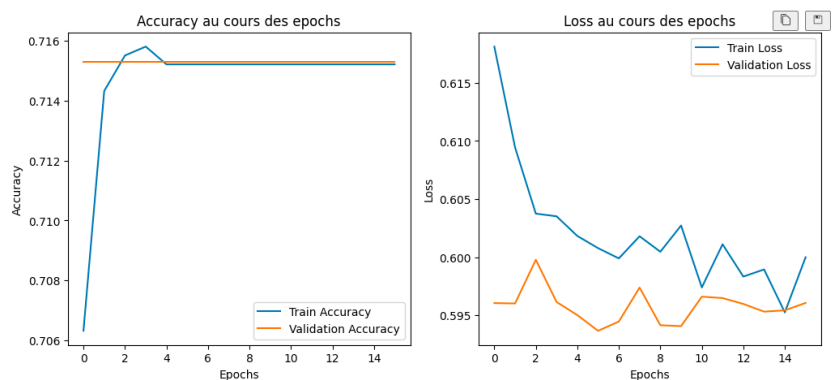


FIGURE 35 – Learning Curve EfficientNetB0

Les courbes d'apprentissage ci-dessus indiquent une stabilisation rapide des performances du modèle dès les premières époques. La perte (loss) diminue légèrement au fil des itérations, aussi bien pour les données d'entraînement que de validation, bien que

l'évolution soit relativement modérée. La précision (accuracy), quant à elle, atteint rapidement un plateau autour de 0,715, avec des valeurs très proches pour l'entraînement et la validation. Cette absence d'écart significatif entre les deux courbes suggère que le modèle ne présente pas de signes de surapprentissage, mais qu'il pourrait bénéficier d'un ajustement plus fin ou d'un entraînement plus long pour améliorer ses performances. Globalement, ces courbes témoignent d'un modèle stable mais potentiellement sous-exploité, qui mériterait un affinement des hyperparamètres ou une stratégie de fine-tuning plus poussée pour libérer tout son potentiel de généralisation.

| Indicateur | Valeur approximative |
|------------------------|----------------------|
| Précision entraînement | 0.80 |
| Précision validation | 0.86 |
| Perte entraînement | ≈ 0.47 |
| Perte validation | ≈ 0.36 |
| Nombre total d'époques | 30 (fine-tuning) |
| Signe d'overfitting | Non observé |

TABLE 1.7 – Résumé des performances d'apprentissage du modèle EfficientNetB0.

5.2.7 Résumé des résultats de classification binaire

| Modèle | Précision | Rappel | F1-Score | Accuracy |
|------------------|-----------|--------|----------|----------|
| Random Forest | 0.85 | 0.80 | 0.82 | 0.86 |
| SVM | 0.94 | 0.91 | 0.93 | 0.94 |
| XGBoost | 0.94 | 0.90 | 0.92 | 0.94 |
| CNN personnalisé | 0.96 | 0.95 | 0.96 | 0.96 |
| ResNet101 | 0.81 | 0.72 | 0.74 | 0.81 |
| EfficientNetB0 | 0.84 | 0.76 | 0.79 | 0.84 |

TABLE 1.8 – Résumé comparatif des performances des différents modèles pour la détection de tumeurs cérébrales.

Parmi l'ensemble des modèles testés pour la classification binaire des images IRM cérébrales, le modèle CNN personnalisé se distingue par ses performances supérieures, avec une précision, un rappel, un F1-score et une exactitude (accuracy) atteignant 0.96. Grâce à cette efficacité remarquable dans la détection des cas avec ou sans tumeur, ce modèle sera retenu pour être intégré dans l'application finale de détection automatique des tumeurs cérébrales.

6 Application2 : Classification Multi-classe

Le défi majeur se pose dans la détection de la tumeur cérébrale en raison de l'emplacement, du type, de la taille et des variations de forme de la tumeur. Le diagnostic de

tumeur cérébrale dépend du type et de l'emplacement de la tumeur afin que les médecins puissent prédire les chances de survie des patients et prendre des décisions de traitement allant de la chirurgie à la radiothérapie et à la chimiothérapie.

Les modèles pré-entraînés que nous allons appliquer dans cette expérience sont EfficientNetB0, VGG16 et ResNet50, tous issus de bibliothèques de vision par ordinateur éprouvées. Ces architectures seront exploitées pour effectuer une classification multi-classes visant à identifier quatre types de tumeurs cérébrales représentés dans la figure suivante. Leur utilisation permet de tirer parti de caractéristiques déjà apprises sur de larges bases d'images (ImageNet), ce qui améliore la convergence et la précision du modèle dans un contexte médical spécifique.

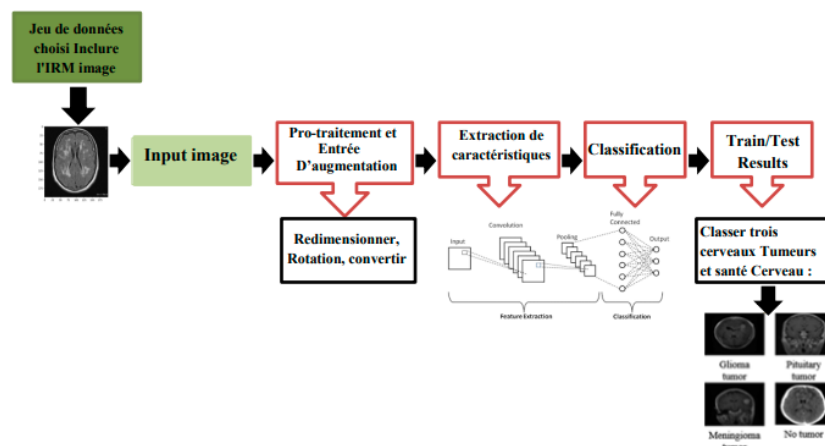


FIGURE 36 – Architecture globale du Modèle propose.

6.1 Acquisition de la base de données

Dans le cadre de la classification multi-classes, nous avons utilisé une base de données publique disponible sur Kaggle, composée de **7023 images d'IRM cérébrales** réparties en **quatre catégories distinctes** : gliome, méningiome, tumeur hypophysaire, et pas de tumeur. Le jeu de données, d'une taille de 156 Mo, est organisé de manière hiérarchique avec des sous-dossiers représentant chaque classe. Plus précisément, il contient : 1621 images de gliome, 1645 images de méningiome, 1757 images de tumeur hypophysaire, et 2000 images sans tumeur. Les images sont déjà séparées en deux ensembles : **Training** (entraînement) et **Testing** (test), facilitant ainsi le processus de modélisation. Ce dataset servira à entraîner les modèles pré-entraînés **VGG16**, **ResNet50** et **EfficientNetB0** afin d'évaluer leur capacité à distinguer efficacement les différents types de tumeurs cérébrales.

6.2 Modèles proposes

6.2.1 EfficientNetB0

Dans le cadre de notre étude sur la classification multi-classes des images IRM cérébrales, nous avons exploité le modèle pré-entraîné **EfficientNetB0**. Ce dernier a été utilisé comme base convolutive, à laquelle nous avons intégré un classifieur personnalisé composé des couches *GlobalAveragePooling2D* et *Dense*, avec une activation *softmax* en sortie pour permettre la classification en quatre catégories. Une couche d'*augmentation de données* a été appliquée en entrée pour renforcer la robustesse du modèle face à la variabilité des données. L'entraînement a été effectué en deux phases : une première étape avec la base gelée, suivie d'un *fine-tuning* progressif, où seules les couches supérieures de l'architecture EfficientNetB0 ont été dégelées. Le processus d'apprentissage a été optimisé à l'aide de techniques de régularisation telles que *EarlyStopping*, *ReduceLROnPlateau* et une stratégie de *stop conditionné sur la précision de validation*. Ce protocole permet d'assurer une convergence stable tout en limitant les risques de surapprentissage.

| Paramètre | Valeur |
|-------------------------|---|
| Architecture | EfficientNetB0 pré-entraîné |
| Taille d'entrée | $224 \times 224 \times 3$ |
| Learning Rate | 0.001 (phase 1), 0.0001 (fine-tuning) |
| Batch Size | 32 |
| Nombre total d'Époques | 60 |
| Optimiseur | Adam |
| Fonction de perte | Sparse Categorical Crossentropy |
| Augmentation de données | Rotation, zoom |
| Régularisation | Dropout, EarlyStopping, ReduceLROnPlateau |
| Fine-tuning | Oui (partiel à partir de la couche 100) |

TABLE 1.9 – Paramètres d'entraînement du modèle EfficientNetB0 personnalisé pour la classification multi-classes.

Visualisation des résultats du modèle

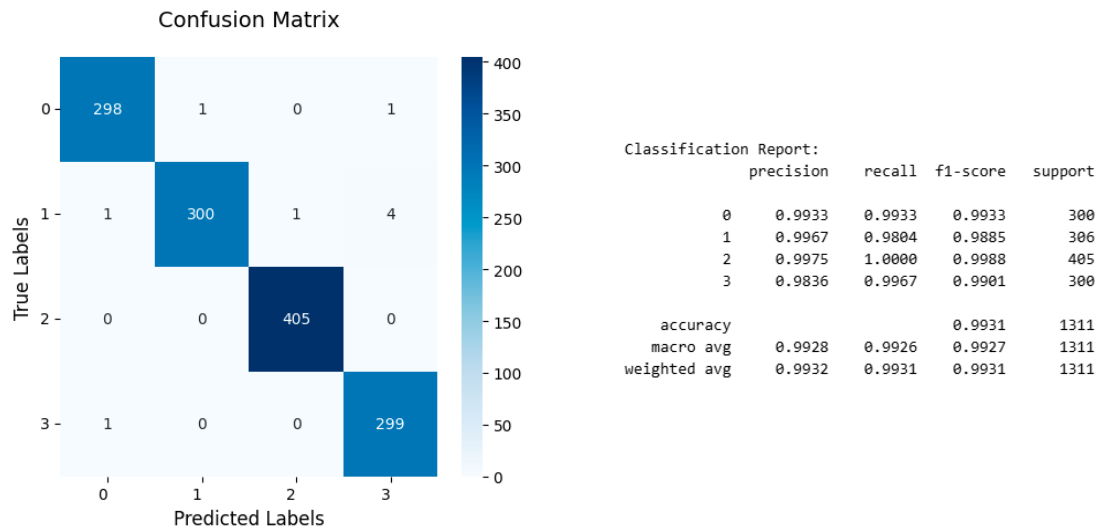


FIGURE 37 – EfficientNetB0(classification multi-classes).

Le modèle basé sur **EfficientNetB0** appliqué à la classification multi-classes des IRM cérébrales montre des performances remarquables, avec une **exactitude globale de 0,9931**, traduisant une capacité exceptionnelle à distinguer entre les quatre types de classes : gliome, méningiome, tumeur hypophysaire, et absence de tumeur. Les scores F1 dépassent 0,98 pour toutes les classes, avec un maximum de **0,9988** pour la classe "pas de tumeur", ce qui témoigne d'une classification presque parfaite. Les précisions et rappels sont également très élevés, la plupart dépassant 0,99, ce qui indique une excellente capacité du modèle à réduire aussi bien les faux positifs que les faux négatifs. La classe "tumeur hypophysaire", souvent plus difficile à distinguer, atteint tout de même un F1-score de **0,9901**. Ces résultats confirment la **robustesse et la fiabilité du modèle EfficientNetB0** pour la tâche de classification fine de tumeurs cérébrales sur IRM.

courbes d'apprentissage

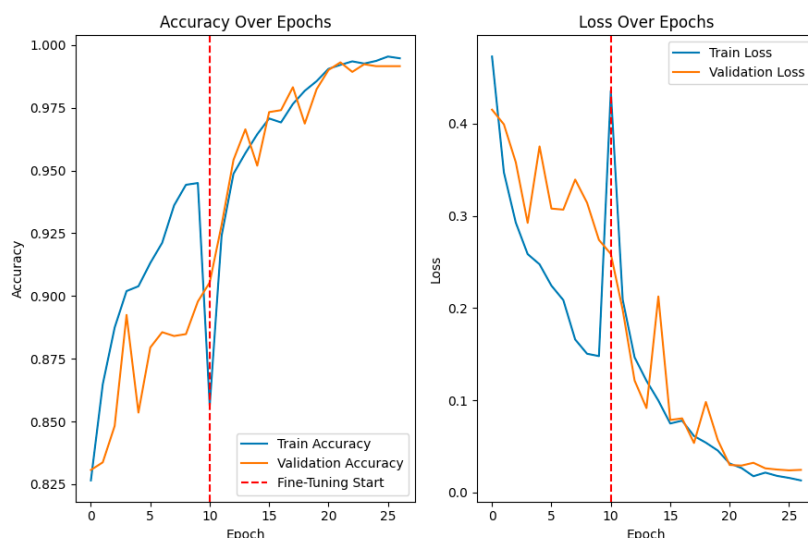


FIGURE 38 – Learning Curve EfficientNetB0(classification multi-classes)

Les courbes d'apprentissage ci-dessus illustrent une progression régulière et cohérente des performances du modèle EfficientNetB0 tout au long des époques. Une première phase de pré-entraînement est suivie d'un point de redémarrage marqué par la ligne rouge verticale, indiquant le début du fine-tuning. Dès cette étape, on observe une nette amélioration de la précision (accuracy) aussi bien sur les données d'entraînement que sur les données de validation, atteignant respectivement des niveaux proches de 1.0, ce qui traduit une excellente capacité d'apprentissage du modèle.

En parallèle, la courbe de la perte (loss) diminue de manière significative sur les deux ensembles, démontrant une optimisation efficace de la fonction de coût sans divergence entre les performances d'entraînement et de validation. L'absence d'écart important entre les courbes de validation et d'entraînement tout au long de l'entraînement indique que le modèle ne souffre pas de surapprentissage, et qu'il généralise bien sur les données non vues.

| Indicateur | Valeur approximative |
|------------------------|--------------------------|
| Précision entraînement | 0.99 |
| Précision validation | 0.99 |
| Perte entraînement | 0.014 |
| Perte validation | 0.025 |
| Nombre total d'époques | 27 (avec early stopping) |
| Signe d'overfitting | Non observé |

TABLE 1.10 – Résumé des performances d'apprentissage du modèle EfficientNetB0 après fine-tuning.

Prédiction des résultats pour EfficientNetB0

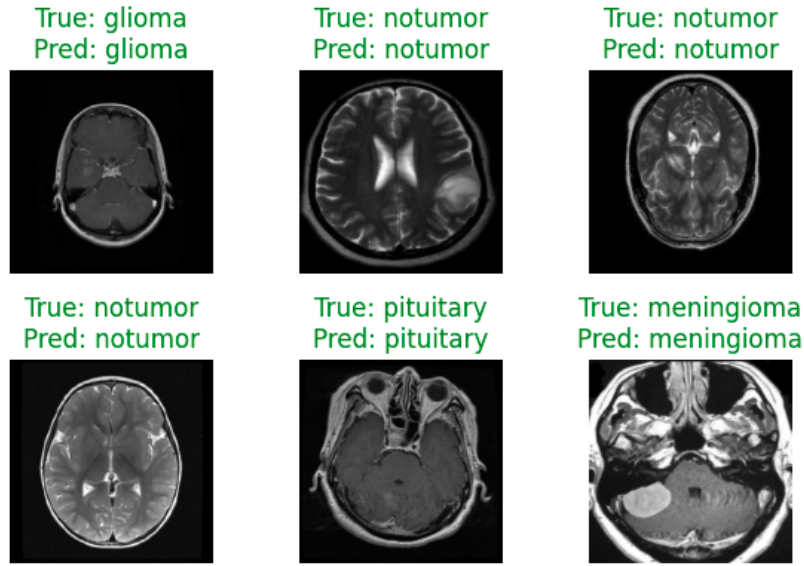


FIGURE 39 – Resultat du EfficientNetB0.

6.2.2 VGG16

Dans notre étude de classification multi-classes d’images IRM cérébrales, nous avons utilisé le modèle pré-entraîné **VGG16** comme base convolutive. La partie supérieure du réseau a été remplacée par un classifieur personnalisé incluant une couche de *GlobalAveragePooling2D*, suivie de normalisation, d’une couche dense de 256 neurones avec activation *ReLU* et d’un *Dropout* pour limiter le surapprentissage. Une couche finale avec activation *softmax* permet la classification en quatre catégories.

L’entraînement a été réalisé sur 20 époques avec augmentation des données (rotation, zoom, décalages, flip horizontal) pour améliorer la généralisation. Les couches convolutives ont été gelées afin de conserver les caractéristiques pré-apprises. Les techniques d’*EarlyStopping* et *ReduceLROnPlateau* ont été utilisées pour optimiser la convergence et éviter le surapprentissage.

| Paramètre | Valeur |
|-------------------------|---|
| Architecture | VGG16 (pré-entraîné ImageNet) |
| Taille d'entrée | $224 \times 224 \times 3$ |
| Batch Size | 32 |
| Nombre d'époques | 20 |
| Optimiseur | Adam |
| Fonction de perte | Categorical Crossentropy |
| Augmentation de données | Rotation, zoom, décalages, flip horizontal |
| Régularisation | Dropout (0.5), EarlyStopping, ReduceLROnPlateau |
| Fine-tuning | Couche convolutive gelée |
| Nombre de classes | 4 |
| Validation | Split 80/20 |

TABLE 1.11 – Paramètres d'entraînement du modèle VGG16 personnalisé pour la classification multi-classes.

Visualisation des résultats du modèle




FIGURE 40 – VGG16(classification multi-classes).

Le modèle basé sur **VGG16**, appliqué à la classification multi-classes des images IRM cérébrales, atteint une exactitude globale de 0,88 sur l'ensemble de test, démontrant une bonne capacité à distinguer les quatre catégories : gliome, méningiome, absence de tumeur, et tumeur hypophysaire. Les scores F1 varient de 0,79 à 0,96, avec un score maximal pour la classe « absence de tumeur » (0,96), traduisant une excellente capacité de classification. La précision et le rappel sont également élevés pour cette classe, atteignant respectivement 0,93 et 0,99, ce qui indique une forte réduction des faux positifs et faux négatifs. La classe « tumeur hypophysaire », souvent difficile à différencier, obtient un score F1 de 0,92 grâce à un rappel remarquable de 0,99. Les classes « gliome » et « méningiome » affichent des performances légèrement plus faibles, notamment un rappel plus modéré pour « gliome » (0,74), mais restent tout à fait satisfaisantes avec des F1-scores respectifs de 0,83 et

0,79. Ces résultats confirment la pertinence du modèle VGG16 pour la classification fine des tumeurs cérébrales sur IRM, en particulier lorsque couplé à une augmentation des données et une régularisation adaptées

courbes d'apprentissage




FIGURE 41 – Learning Curve VGG16(classification multi-classes)

Les courbes d'apprentissage ci-dessus montrent une progression régulière et stable des performances du modèle VGG16 sur l'ensemble des 20 époques. La précision (accuracy) augmente rapidement dès les premières époques, atteignant environ 0,93 en entraînement et 0,87 en validation à la fin de l'apprentissage. Cette tendance indique une bonne capacité d'apprentissage du modèle.

Parallèlement, la courbe de la perte (loss) décroît significativement sur l'ensemble d'entraînement, avec une diminution plus modérée mais progressive sur les données de validation. On note toutefois un léger écart entre les courbes de perte validation et entraînement, témoignant d'une possible tendance à un léger surapprentissage, mais sans impact majeur sur la précision. L'absence de fluctuations brusques et la convergence des courbes suggèrent que le modèle généralise globalement bien sur des données non vues.

| Indicateur | Valeur approximative |
|------------------------|------------------------|
| Précision entraînement | 0.92 |
| Précision validation | 0.85 |
| Perte entraînement | 0.22 |
| Perte validation | 0.45 |
| Nombre total d'époques | 20 |
| Signe d'overfitting | Non clairement observé |

TABLE 1.12 – Résumé des performances du modèle VGG16 après entraînement avec transfert learning.

Prédiction des résultats pour VGG16




FIGURE 42 – Resultat du VGG16.

6.2.3 ResNet50

Dans le cadre de notre expérimentation, nous avons également exploité le modèle **ResNet50** pré-entraîné sur ImageNet comme base convolutive. L'architecture a été adaptée en supprimant la tête de classification initiale au profit d'un classifieur personnalisé. Celui-ci se compose d'une couche de *GlobalAveragePooling2D*, suivie d'une normalisation par lot, d'une couche dense de 256 neurones avec activation *ReLU*, et d'un *Dropout* à 0.5. La couche finale utilise une activation *softmax* pour effectuer la classification parmi quatre classes.

L'entraînement a été réalisé sur 20 époques avec des techniques d'augmentation de données (rotation, zoom, translation, retournement horizontal) afin de renforcer la robustesse du modèle. Toutes les couches convolutives du modèle de base ont été gelées pour conserver les caractéristiques générales. Des callbacks comme *EarlyStopping* et *ReduceLROnPlateau* ont été intégrés pour améliorer la stabilité et l'efficacité de l'apprentissage.

| Paramètre | Valeur |
|-------------------------|---|
| Architecture | ResNet50 (pré-entraîné ImageNet) |
| Taille d'entrée | $224 \times 224 \times 3$ |
| Batch Size | 32 |
| Nombre d'époques | 20 |
| Optimiseur | Adam |
| Fonction de perte | Categorical Crossentropy |
| Augmentation de données | Rotation, zoom, décalages, flip horizontal |
| Régularisation | Dropout (0.5), EarlyStopping, ReduceLROnPlateau |
| Fine-tuning | Couche convolutive gelée |
| Nombre de classes | 4 |
| Validation | Split 80/20 |

TABLE 1.13 – Paramètres d'entraînement du modèle ResNet50 personnalisé pour la classification multi-classes.

Visualisation des résultats du modèle

Le modèle basé sur **ResNet50** a atteint une exactitude globale de 0,75 sur l'ensemble




FIGURE 43 – ResNet50(classification multi-classes).

de test, révélant une performance correcte pour la classification multi-classes des IRM cérébrales. Le modèle excelle particulièrement sur la classe *absence de tumeur*, avec un **F1-score de 0,88**, une précision de 0,81 et un rappel de 0,96, ce qui traduit une capacité très fiable à identifier les cas sains. La classe *tumeur hypophysaire* bénéficie également d'un **rappel très élevé (0,99)**, ce qui permet de limiter les cas manqués, bien que sa précision plus modérée (0,70) entraîne un F1-score de 0,82. En revanche, les classes *gliome* et *méningiome* présentent des résultats plus faibles. Le rappel de la classe *gliome* est particulièrement limité (0,51), avec un F1-score de 0,62, ce qui suggère des difficultés à détecter cette pathologie. De même, la classe *méningiome* obtient un F1-score de 0,53, reflétant une performance à améliorer. La moyenne pondérée des F1-scores s'élève à 0,73, ce qui reste satisfaisant dans un contexte multi-classe complexe.

courbes d'apprentissage




FIGURE 44 – Learning Curve ResNet50(classification multi-classes)

Les courbes d'apprentissage du modèle **ResNet50** montrent une évolution progressive

des performances au fil des 20 époques. La précision en entraînement augmente régulièrement pour atteindre environ 0,78, tandis que la précision en validation progresse plus lentement et se stabilise autour de 0,72. Cette évolution traduit une capacité d'apprentissage raisonnable, bien que l'écart entre les deux courbes suggère une légère tendance au surapprentissage.

Du côté de la perte, on observe une diminution continue sur les données d'entraînement, atteignant une valeur inférieure à 0,6 en fin d'apprentissage. La perte de validation, quant à elle, connaît une baisse notable au début, avant de fluctuer légèrement autour de 0,8. Ces fluctuations indiquent une instabilité modérée dans la généralisation du modèle sur des données non vues. Néanmoins, l'absence de divergences majeures ou de comportements erratiques laisse penser que l'apprentissage s'est déroulé de manière globalement stable et contrôlée.

| Indicateur | Valeur approximative |
|------------------------|----------------------|
| Précision entraînement | 0.78 |
| Précision validation | 0.72 |
| Perte entraînement | 0.55 |
| Perte validation | 0.80 |
| Nombre total d'époques | 20 |
| Signe d'overfitting | Légèrement présent |

TABLE 1.14 – Résumé des performances du modèle ResNet50 après entraînement avec transfert learning.

Prédiction des résultats pour ResNet




FIGURE 45 – Resultat du ResNet.

6.2.4 Résumé des résultats de classification multi-classes

| Modèle | Précision | Rappel | F1-Score | Accuracy |
|----------------|-----------|--------|----------|----------|
| VGG16 | 0.89 | 0.88 | 0.88 | 0.88 |
| ResNet50 | 0.74 | 0.75 | 0.73 | 0.75 |
| EfficientNetB0 | 0.99 | 0.99 | 0.99 | 0.99 |

TABLE 1.15 – Résumé comparatif des performances des modèles pour la classification multi-classes de tumeurs cérébrales.

Parmi l'ensemble des modèles testés pour la classification multi-classes des images IRM cérébrales, le modèle **EfficientNetB0** se distingue par ses performances remarquables, avec une précision, un rappel, un F1-score et une exactitude (accuracy) proches de 0.99. Cette performance exceptionnelle reflète une excellente capacité à distinguer les différentes catégories de tumeurs cérébrales ainsi que les cas sains. En raison de cette fiabilité élevée, le modèle EfficientNetB0 sera retenu comme solution de référence pour une classification automatisée et précise des IRM dans le cadre d'un système d'aide au diagnostic.

7 Présentation du système :

L'application « Détection et Classification de Tumeurs Cérébrales » est une plateforme interactive développée avec Streamlit, permettant l'analyse automatique d'images IRM cérébrales. Elle repose sur un modèle CNN (Convolutional Neural Network) pour détecter la présence de tumeurs, et sur le modèle EfficientNetB0 pour classer le type de tumeur identifiée. L'interface simple et intuitive permet à l'utilisateur de téléverser une image médicale via un bouton dédié. Une fois l'image chargée, elle s'affiche en aperçu dans l'interface. L'utilisateur peut ensuite lancer la détection à l'aide d'un bouton spécifique : si une tumeur est détectée, un second bouton permet de classer l'image. Les résultats sont alors affichés de façon claire, indiquant d'une part la présence ou non d'une tumeur, et d'autre part le type de tumeur identifié. Cette solution, combinant deep learning et ergonomie web, vise à offrir un outil d'aide au diagnostic efficace, rapide et accessible pour les professionnels de santé



FIGURE 46 – Interface principale de système.

8 Les résultats du système :

Les figures ci-dessous montrent quelques tests et leurs résultats.

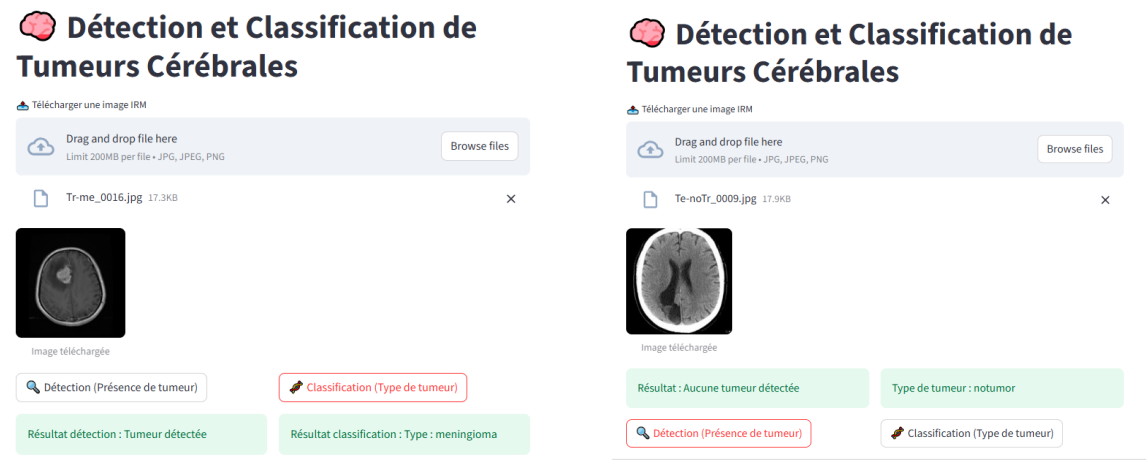


FIGURE 47 – Détection et classification en temps réel des Tumeurs Cérébrale.

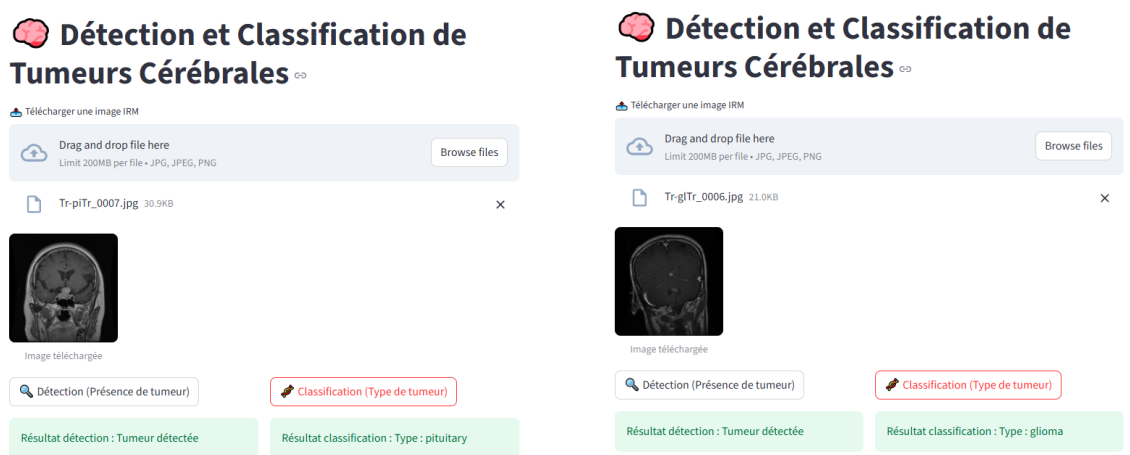


FIGURE 48 – Détection et classification en temps réel des Tumeurs Cérébrale.

9 Conclusion :

Ce chapitre a détaillé notre approche méthodologique pour la classification des tumeurs cérébrales en IRM, en comparant plusieurs modèles d'apprentissage automatique et profond. Les résultats ont confirmé l'efficacité du CNN personnalisé pour la détection binaire (96% de précision) et d'EfficientNetB0 pour la classification multi-classe (99% de précision). L'application Streamlit développée permet une analyse rapide et intuitive des IRM, offrant une aide précise au diagnostic. Ces travaux ouvrent des perspectives pour l'assistance médicale automatisée, tout en soulignant l'importance du prétraitement et de

l'augmentation des données pour optimiser les performances. Cette étude valide le potentiel de l'IA dans le diagnostic des tumeurs cérébrales et propose des pistes d'amélioration pour une intégration clinique plus large.

Conclusion et Perspectives

Conclusion

Dans ce travail de recherche, nous avons mené une étude approfondie sur l'application des techniques d'intelligence artificielle pour la détection et la classification des tumeurs cérébrales à partir d'images IRM. Notre recherche a permis d'identifier les défis majeurs du diagnostic médical dans ce domaine tout en démontrant le potentiel transformateur des approches modernes d'apprentissage profond.

Nous avons conçu et implémenté un système innovant combinant différentes architectures de réseaux neuronaux, avec des résultats particulièrement prometteurs. Notre modèle EfficientNetB0 a notamment démontré une capacité remarquable à classifier différents types de tumeurs avec une précision exceptionnelle (99,31%), surpassant les méthodes traditionnelles d'analyse d'images.

Les résultats obtenus confirment que les techniques d'apprentissage profond sont parfaitement adaptées aux exigences du diagnostic médical en neuro-oncologie, avec des applications potentielles dans :

- Le dépistage précoce des tumeurs cérébrales.
- L'aide à la décision pour les radiologues.
- La standardisation des diagnostics.

Cependant, certaines limitations ont été identifiées, notamment concernant la taille et la diversité des données d'entraînement, ouvrant ainsi des perspectives d'amélioration pour les recherches futures. Ce travail établit une base solide pour le développement de solutions avancées en imagerie médicale assistée par IA.

Perspectives

Plusieurs axes de recherche prometteurs se dégagent de ce travail :

- Extension à d'autres modalités d'imagerie : Adapter le système pour traiter d'autres types d'exams (scanner, PET-scan) , Développer des approches multimodales combinant plusieurs sources d'imagerie.
- Amélioration des capacités diagnostiques : intégrer la détection de tumeurs rares ou atypiques, Développer des fonctionnalités de pronostic et d'évaluation de la réponse au traitement.
- Applications cliniques élargies : Étendre la technologie à d'autres pathologies cérébrales (AVC, maladies neurodégénératives) ,Développer des solutions pour le suivi longitudinal des patients.

Ces perspectives ouvrent la voie à une nouvelle ère du diagnostic médical, où l'intelligence artificielle viendra renforcer l'expertise humaine pour améliorer la prise en charge des patients atteints de pathologies cérébrales.

Bibliographie

- [1] Bassett, D. S. & Gazzaniga, M. S. (2011). Understanding complexity in the human brain. *Trends in Cognitive Sciences*.
- [2] Bear, M. F., Connors, B. W. & Paradiso, M. A. (2016). *Neurosciences : à la découverte du cerveau*. John Libbey Eurotext.
- [3] Kolb, B., Whishaw, I. Q. & Teskey, G. C. (2019). *Cerveau et comportement*. De Boeck Supérieur.
- [4] Barlow, D. H., Durand, V. M. & Gottschalk, M. (2016). *Psychopathologie : une approche intégrative*. De Boeck supérieur.
- [5] Nevid, J. S., Rathus, S. & Greene, B. (2009). *Psychopathologie*. Pearson Education France.
- [6] Crossman, A. R. & Neary, D. (2018). *Neuroanatomy E-book : an illustrated colour text*. Elsevier Health Sciences.
- [7] Tortora, G. J. & Derrickson, B. (2017). *Manuel d'anatomie et de physiologie humaines*. De Boeck supérieur.
- [8] Sakka, L. & Chazal, J. (2005). Les méninges vues par l'anatomiste. *Morphologie*.
- [9] Katti, G., Ara, S. A. & Shireen, A. (2011). Magnetic resonance imaging (mri)—a review. *International journal of dental clinics*.
- [10] Grand, S. et al. (2012). Principes fondamentaux de l'imagerie par résonance magnétique. *Pratique Neurologique-FMC*.
- [11] Serai, S. D., Ho, M.-L., Artunduaga, M., Chan, S. S. & Chavhan, G. B. (2021). Components of a magnetic resonance imaging system and their relationship to safety and image quality. *Pediatric radiology*, 716–723.
- [12] Lapointe, S., Perry, A. & Butowski, N. A. (2018). Primary brain tumours in adults. *The Lancet*.
- [13] Guillamo, J.-S. et al. (2008). Traitement actuel des métastases cérébrales. *Revue neurologique*.
- [14] Delannes, M. et al. (2016). Radiothérapie des tumeurs intracrâniennes bénignes. *Cancer/Radiothérapie*.

- [15] Verreault, M., Delattre, J. Y. & Idbaih, A. (2012). Les tumeurs gliales diffuses de l'adulte-hétérogénéité génétique et implications thérapeutiques. *médecine/sciences*.
- [16] Delipetrev, B., Tsinaraki, C. & Kostic, U. (2020). Historical evolution of artificial intelligence.
- [17] Flasiński, M. (2016). *Introduction to artificial intelligence*. Springer.
- [18] Jiang, F. et al. (2017). Artificial intelligence in healthcare : past, present and future. *Stroke and vascular neurology*.
- [19] Jakhar, D. & Kaur, I. (2020). Artificial intelligence, machine learning and deep learning : definitions and differences. *Clinical and Experimental Dermatology*.
- [20] Attaran, M. & Deb, P. (2018). Machine learning : the new 'big thing' for competitive advantage. *International Journal of Knowledge Engineering and Data Mining*.
- [21] Tassew, T. & Nie, X. (2023). A comprehensive review of the application of machine learning in medicine and health care. *Authorea Preprints*.
- [22] Hasan, M. & Boris, F. (2006). Svm : Machines à vecteurs de support ou séparateurs à vastes marges. *Tech. Rep.*, Versailles St Quentin, France.
- [23] Zidelmal, Z. (2012). Reconnaissance d'arythmies cardiaques par Support Vector Machines. *Ph.D. thesis*.
- [24] Chapron, M. & Assemat, L. (2005). Classification de végétaux par svm. *In GRETSI*.
- [25] Do, T. N. & Poulet, F. (2005). Svm et visualisation pour la fouille de grands ensembles de données. *In EGC*.
- [26] Kallas, M. et al. (2012). Multi-class svm classification combined with kernel pca feature extraction of ecg signals. *In 2012 19th International Conference on Telecommunications (ICT)*. IEEE.
- [27] Alfonse, M. & Salem, A. M. (2012). An Automatic Classification of Brain Tumors through MRI Using Support Vector Machine. Computer Science Department, Faculty of Computers and Information Sciences, Ain Shams University, Cairo, Egypt.
- [28] Kumar, A., Ashok, A., & Ansari, M. A. (2024). Brain Tumor Classification Using Hybrid Model Of PSO And SVM Classifier. Département de génie informatique et de génie électrique, Université technique d'Uttarakhand, Dehradun, Inde ; Institut de technologie pour femmes, Dehradun, Inde ; Département de génie électrique, Université Gautam Buddha, Greater Noida, Inde.
- [29] Hussain, A., & Khunteta, A. (2024). Semantic Segmentation of Brain Tumor from MRI Images and SVM Classification using GLCM Features. Département de génie électronique, Université technique du Rajasthan, Kota, Inde.
- [30] Zafar, M. Z., Adnan, S. M., Ahmad, W., Ikram, J., & Rashid, J. (2024). Brain Tumor Detection and Classification Using Geometrical Shapes as Texture Descriptors.

Département d'informatique, Université d'ingénierie et de technologie de Taxila, Pakistan ; École des sciences informatiques, Institut de communication graphique de Beijing, Chine.

- [31] Cheng, J., Huang, W., Cao, S., Yang, R., Yang, W., Yun, Z., Wang, Z., & Feng, Q. (2024). Enhanced Performance of Brain Tumor Classification via Tumor Region Augmentation and Partition. School of Biomedical Engineering, Southern Medical University, Guangzhou, China ; Department of Obstetrics and Gynecology, Nanfang Hospital of Southern Medical University, Guangzhou, China.
- [32] Kharrat, A., & Ben Halimal, M. (2024). MRI Brain Tumor Classification using Support Vector Machines and Meta-Heuristic Method. IREGIM-Lab. : "REsearch Groups in Intelligent Machines, University of Sfax, ENIS, BP 1173, Sfax, 3038, Tunisia ; Higher Institute of Computer Science and Multimedia of Sfax, University of Sfax, Tunisia.
- [33] Wasule, V., & Sonar, P. (2024). Classification of Brain MRI Using SVM and KNN Classifier. Department of Electronics and Telecommunication Engineering, Rajiv Gandhi Institute of Technology, Andheri, Mumbai.